Classification Assignment

Matrikelnummer: 2130238

Zielvariable: `Churn`

> **Hinweis zu Task 1 (Data Preprocessing):** Die Datensäuberung und das Feature Engineering wurden zentral im separaten Notebook `data_pre-processing.ipynb` durchgeführt. Dieses Notebook startet direkt mit dem Laden des bereinigten Datensatzes `dataset_cleaned.csv`.

- **Task 1:** Data Preprocessing → siehe `data_pre-processing.ipynb`
- **Task 2:** Basismodelle (KNN, Decision Tree, Logistische Regression)
- **Task 3:** Optimierung des besten Modells (Hyperparameter-Tuning)
- **Task 4:** Ensemble Learning (Random Forest, Gradient Boosting)

Importieren von Bibliotheken

In [1]:
```
# ── Bibliotheken ──────────────────────────────────────────────────
import warnings
import joblib
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# Sklearn – Modellauswahl & Vorverarbeitung
from sklearn.model_selection import (
    train_test_split, StratifiedKFold,
    GridSearchCV, RandomizedSearchCV,
    cross_validate, learning_curve
)
from sklearn.preprocessing import StandardScaler

# Sklearn – Modelle
from sklearn.neighbors   import KNeighborsClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.tree        import DecisionTreeClassifier
from sklearn.ensemble    import RandomForestClassifier, GradientBoostingClassifi

# Sklearn – Metriken
from sklearn.metrics import (
    accuracy_score, precision_score, recall_score,
    f1_score, confusion_matrix, ConfusionMatrixDisplay, roc_auc_score
)

# Imbalanced-learn
from imblearn.pipeline      import Pipeline
from imblearn.over_sampling import SMOTE

warnings.filterwarnings('ignore')
```

```
# ── Globale Konstanten ──────────────────────────────────────────────
RANDOM_STATE = 42
TEST_RATIO   = 0.3
MAX_ITER     = 500
```

Task 1: Data Preprocessing

Das Preprocessing wurde vollständig im separaten Notebook `data_preprocessing.ipynb` durchgeführt. Hier wird der bereits bereinigte Datensatz direkt eingelesen. Folgende Schritte wurden dort vorgenommen:

- Fehlende Werte behandelt (`CEstimatedSalary` → länderspez. Mittelwert, `CBalance` → Median-Imputation)
- Ausreißer bereinigt (IQR für `CCreditScore` , `CTenure` , `Support_Tickets_Count` , `Avg_Monthly_Transactions`)
- Inkonsistenzen behoben (`CGeography` , `CGender` , `CNumOfProducts`)
- Feature Engineering: `CSeason` aus `Onboarding_Month` , Dummy-Encoding, Rundung
- Export als `dataset_cleaned.csv`

Bereinigten Datensatz laden und für Klassifikation vorbereiten

In [2]:
```
# Bereinigten Datensatz laden
df = pd.read_csv("../data/dataset_cleaned.csv")

# Features und Zielvariable
X = df.drop(['Churn', 'CLV_Continuous'], axis=1)
y = df['Churn']

# Datentypen prüfen
print("="*25, "Datentypen der Features:", "="*25, "\n")
print(X.dtypes, "\n")
print("Datentyp der Zielvariable:", y.dtype)

# Train/Test-Split (70/30)
# stratify=y stellt sicher, dass die Klassenverteilung (~7% Churn)
# in beiden Splits erhalten bleibt
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=TEST_RATIO,
    random_state=RANDOM_STATE,
    stratify=y
)

print(f"\nTrainingsset: {X_train.shape[0]} Beobachtungen | Churn-Anteil: {y_trai
print(f"Testset:      {X_test.shape[0]}  Beobachtungen | Churn-Anteil: {y_test.m
```

```
========================= Datentypen der Features: =========================

CCreditScore                float64
CAge                          int64
CTenure                       int64
CBalance                    float64
CNumOfProducts                int64
CHasCrCard                    int64
CIsActiveMember               int64
CEstimatedSalary              int64
Account_Age_Months            int64
Avg_Monthly_Transactions      int64
Transaction_Variance        float64
Last_Login_Days_Ago           int64
Support_Tickets_Count         int64
Mobile_App_Usage_Hours      float64
Is_Holiday_Onboarding         int64
CBalance_is_negative          int64
CGeography_Germany            int64
CGeography_Spain              int64
CGender_Male                  int64
CSeason_Spring                int64
CSeason_Summer                int64
CSeason_Winter                int64
dtype: object

Datentyp der Zielvariable: int64

Trainingsset: 5964 Beobachtungen | Churn-Anteil: 7.33%
Testset:      2557  Beobachtungen | Churn-Anteil: 7.35%
```

Im Folgenden ist eine Skalierung für den kNN und die logistische Regression notwendig, da diese Algorithmen auf Distanz- bzw. Gradientenberechnungen basieren und empfindlich auf unterschiedliche Wertebereiche reagieren. Beispielsweise liegen `CCreditScore`-Werte zwischen 400 und 850, `CBalance`-Werte hingegen im sechsstelligen Bereich – ohne Skalierung würde `CBalance` die Distanzberechnung stark dominieren.

Mit dem `StandardScaler` werden die Feature-Werte transformiert ($z = (x - \mu) / \sigma$), sodass alle skalierten Features einen Mittelwert von 0 und eine Standardabweichung von 1 erhalten.

Wichtig: Binäre Spalten (0/1) und One-Hot-codierte Variablen werden bewusst **nicht** skaliert, da ihre Werte bereits eine eindeutige kategoriale Bedeutung besitzen und eine Skalierung diese verzerren würde.

In [3]:
```python
# Bestimme, welche Spalten skaliert werden sollen
# Binäre Spalten (nur Werte 0 und 1) werden NICHT skaliert
binary_cols = [col for col in X_train.columns if set(X_train[col].unique()) <= {
scale_cols  = [col for col in X_train.columns if col not in binary_cols]

print(f"Zu skalierende Features:     {len(scale_cols)}")
print(f"Nicht skalierte (binäre):    {len(binary_cols)}")
print(f"Binäre Spalten: {binary_cols}")

# StandardScaler: fit NUR auf Trainingsdaten, damit Testdaten keinen Einfluss ha
scaler = StandardScaler()
```

```
X_train_scaled = X_train.copy()
X_test_scaled  = X_test.copy()

X_train_scaled[scale_cols] = scaler.fit_transform(X_train[scale_cols])
X_test_scaled[scale_cols]  = scaler.transform(X_test[scale_cols])

print("\nSkalierung abgeschlossen.")
pd.DataFrame(X_train_scaled[scale_cols]).head()
```

```
Zu skalierende Features:     12
Nicht skalierte (binäre):    10
Binäre Spalten: ['CHasCrCard', 'CIsActiveMember', 'Is_Holiday_Onboarding', 'CBala
nce_is_negative', 'CGeography_Germany', 'CGeography_Spain', 'CGender_Male', 'CSea
son_Spring', 'CSeason_Summer', 'CSeason_Winter']

Skalierung abgeschlossen.
```

Out[3]:

	CCreditScore	CAge	CTenure	CBalance	CNumOfProducts	CEstimatedSalary
1819	0.854666	-0.297132	1.023164	0.857250	-1.009883	-0.017809
655	-1.950143	0.380904	-0.710303	0.158637	-1.009883	1.136610
1455	0.174264	0.671490	-0.710303	-1.151670	0.874642	1.168273
281	-0.861488	-0.587718	-1.750384	1.194415	-1.009883	1.635387
1807	-1.020151	-1.556341	1.023164	-1.170998	0.874642	0.787797

In [4]:

```
df.describe()
```

Out[4]:

	CCreditScore	CAge	CTenure	CBalance	CNumOfProducts	CHasC
count	8521.000000	8521.000000	8521.000000	8521.000000	8521.000000	8521.0
mean	651.587720	37.990964	5.022063	74032.943075	1.535383	0.7
std	95.697872	10.373745	2.880562	62580.470722	0.531583	0.4
min	402.120000	18.000000	0.000000	-7218.834421	1.000000	0.0
25%	585.094000	31.000000	3.000000	758.791451	1.000000	0.0
50%	653.114000	36.000000	5.000000	93650.834343	2.000000	1.0
75%	717.707000	42.000000	7.000000	126615.633468	2.000000	1.0
max	857.458000	84.000000	10.000000	220214.292303	4.000000	1.0

8 rows × 24 columns

Task 2: KNN - Algorithmus

Berechne geeigneten n_neigbors

In [5]:
```
# Finde den besten Parameter für "n_neighbors" (oft auch "k" genannt)
train_accuracies = {}
test_accuracies = {}
neighbors = np.arange(1, 15)

for neighbor in neighbors:
    knn = KNeighborsClassifier(n_neighbors=neighbor)
    knn.fit(X_train_scaled, y_train)

    train_accuracies[neighbor] = knn.score(X_train_scaled, y_train)
    test_accuracies[neighbor] = knn.score(X_test_scaled, y_test)
```

In [6]:
```
accuracy = []

# Fehlerrate für K-Werte zwischen 1 und 14 berechnen
for i in range(1, 15):
    knn_classifier = KNeighborsClassifier(n_neighbors=i)
    knn_classifier.fit(X_train_scaled, y_train)
    pred_i = knn_classifier.predict(X_test_scaled)
    accuracy.append(accuracy_score(y_test, pred_i))
```

In [7]:
```
# Visualisierung: Trainings- und Test-Accuracy sowie Fehlerrate für verschiedene
fig, axes = plt.subplots(1, 2, figsize=(10, 5))
fig.suptitle('Bestes K für KNN bestimmen', fontsize=16, fontweight='bold')

# Anzahl der K-engsten Nachbarn
axes[0].plot(neighbors, train_accuracies.values(), label="Trainings-Accuracy")
axes[0].plot(neighbors, test_accuracies.values(), label="Test-Accuracy")
axes[0].set_title('KNN: Variation der Nachbarzahl')
axes[0].legend()
axes[0].set_xlabel("Anzahl der Nachbarn")
axes[0].set_ylabel("Genauigkeit")
axes[0].grid(True, alpha=0.3)

# Fehlerrate für K-engste Nachbarn
axes[1].plot(accuracy)
axes[1].set_title('KNN: Variation der Nachbarzahl')
axes[1].set_xlabel("K")
axes[1].set_ylabel("Genauigkeit")
axes[1].grid(True, alpha=0.3)
```

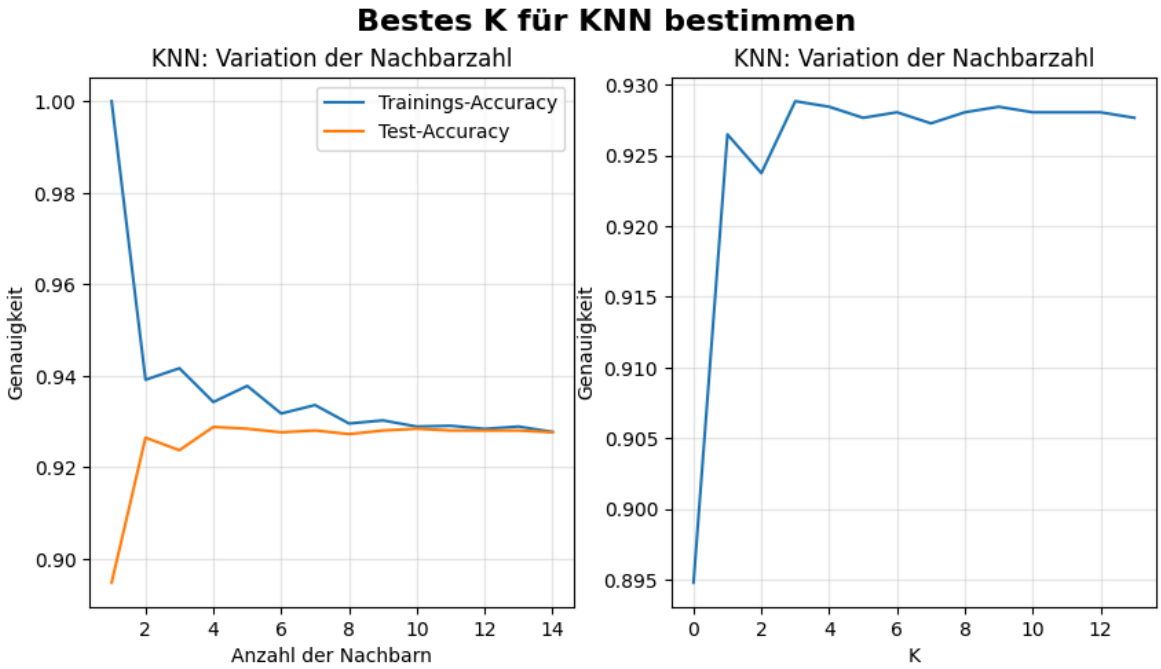

KNN trainieren

In [8]:
```
# KNN-Modell erstellen und auf Trainingsdaten trainieren
knn = KNeighborsClassifier(n_neighbors=7)
knn.fit(X_train_scaled, y_train)

# Vorhersagen auf dem Testset erstellen
y_pred_test_knn = knn.predict(X_test_scaled)
```

KNN auswerten

In [9]:
```
# Modellgenauigkeit berechnen
print("Accuracy:", accuracy_score(y_test, y_pred_test_knn))
# Präzision berechnen
print("Precision:", precision_score(y_test, y_pred_test_knn))
# Recall berechnen
print("Recall:", recall_score(y_test, y_pred_test_knn))
# F1-Score berechnen
print("F1-Score:", f1_score(y_test, y_pred_test_knn))
# AUC-ROC Score berechnen
print("AUC-ROC:", roc_auc_score(y_test, knn.predict_proba(X_test_scaled)[:, 1]))
```

```
Accuracy: 0.9280406726632773
Precision: 0.625
Recall: 0.05319148936170213
F1-Score: 0.09803921568627451
AUC-ROC: 0.6586976729565396
```

In [10]:
```
# Konfusionsmatrix für KNN auf Testdaten
ConfusionMatrixDisplay.from_estimator(knn, X_test_scaled, y_test, values_format=
plt.title("Konfusionsmatrix – KNN (k=7) auf Testdaten")
plt.show()
```

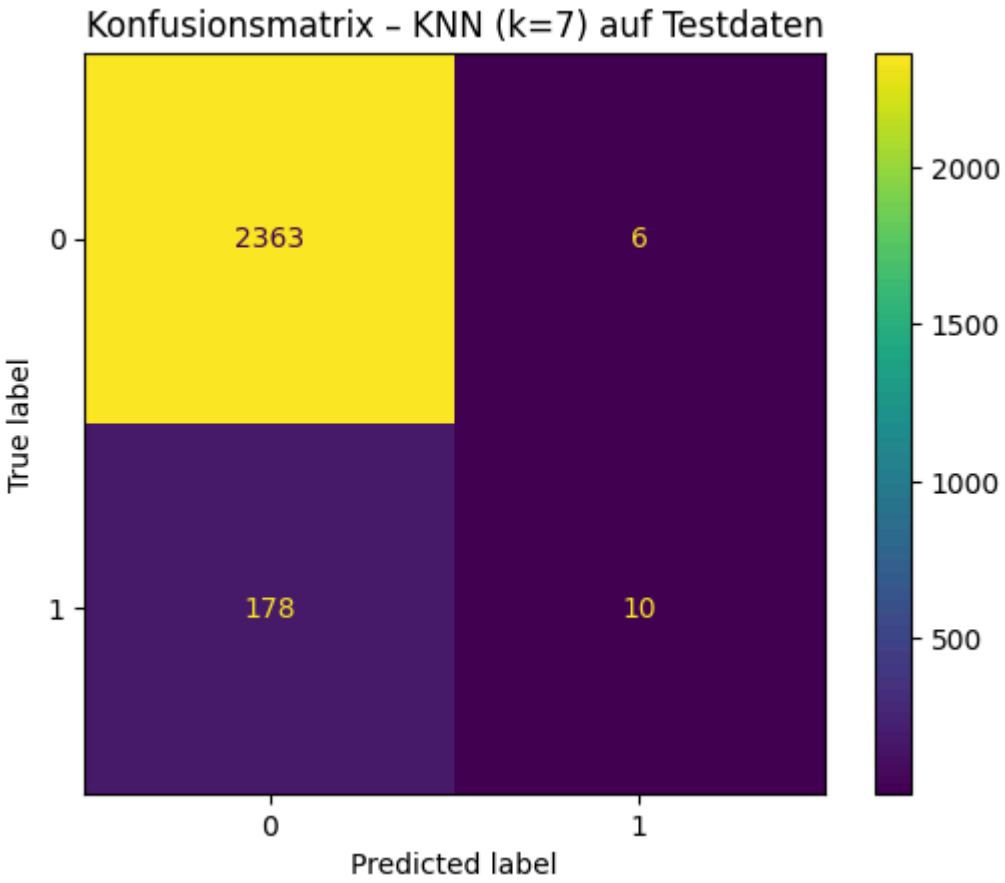

In [11]:
```
# Überprüfe die Klassenverteilung
print("Klassenverteilung im Trainingsset:")
print(y_train.value_counts())
print(f"Anteil Churn: {y_train.mean():.4f}")

print("\nKlassenverteilung im Testset:")
print(y_test.value_counts())
print(f"Anteil Churn: {y_test.mean():.4f}")
```

```
Klassenverteilung im Trainingsset:
Churn
0    5527
1     437
Name: count, dtype: int64
Anteil Churn: 0.0733

Klassenverteilung im Testset:
Churn
0    2369
1     188
Name: count, dtype: int64
Anteil Churn: 0.0735
```

Auswertung KNN (unbalancierter Datensatz)

Die Accuracy von 92,80 % sieht zunächst gut aus, ist hier aber wenig aussagekräftig – da nur ~7,4 % der Kunden churnen, könnte das Modell einfach immer "Kein Churn" vorhersagen und wäre trotzdem in ~92 % der Fälle "richtig". Auf dieses Problem wurde bereits in Task 1 beim Data-Cleaning hingewiesen.

Entscheidend sind Recall und F1-Score: Der Recall von 5,32 % bedeutet, dass das Modell fast keine Churn-Kunden findet. Von 188 echten Abwanderern identifiziert das Modell gerade einmal ~10 – das ist für die Praxis nicht verwendbar. Die Precision von 62,5 % klingt auf den ersten Blick gut, ist aber wenig aussagekräftig, wenn das Modell insgesamt so selten positiv vorhersagt.

KNN fällt hier vor allem durch das Klassenungleichgewicht aus dem Rennen: Bei k=7 dominieren die "Kein Churn"-Nachbarn statistisch fast immer. Der F1-Score von 9,80 % fasst das zusammen – kein brauchbares Modell für diesen Use-Case.

Classification mit Decision-Tree

In [12]:
```
# Decision-Tree-Klassifizierer erstellen
clf_tree = DecisionTreeClassifier(random_state=RANDOM_STATE)

# Modell auf Trainingsdaten trainieren
clf_tree = clf_tree.fit(X_train, y_train)

# Basismodell-Eigenschaften ausgeben
print(f"Baseline Tree Depth: {clf_tree.get_depth()}")
print(f"Baseline Leaf Nodes: {clf_tree.get_n_leaves()}")
```

```
Baseline Tree Depth: 22
Baseline Leaf Nodes: 410
```

Ohne Einschränkungen durch Hyperparameter wächst der Baum auf eine Tiefe von 22 mit 410 Blattknoten – das ist ein deutliches Zeichen für starkes Overfitting. Der Algorithmus hat die Trainingsdaten sehr granular auswendig gelernt, anstatt allgemeine Muster zu erkennen. Ein so tiefer Baum ist typischerweise auf den Trainingsdaten nahezu perfekt,generalisiert auf unbekannten Testdaten aber kaum. Wie stark das Overfitting tatsächlich ist, zeigt die Gegenüberstellung der Metriken auf Trainings- und Testdaten im nächsten Schritt.

In [13]:
```
# Prädiziere das Ergebnis für die Testdaten
y_pred_test_clf_tree = clf_tree.predict(X_test)

# Konfusionsmatrix visualisieren auf Testdaten
cmm = confusion_matrix(y_test, y_pred_test_clf_tree)
ConfusionMatrixDisplay.from_estimator(clf_tree, X_test, y_test, values_format='d
plt.title("Konfusionsmatrix – Decision Tree auf Testdaten")
plt.show()
```

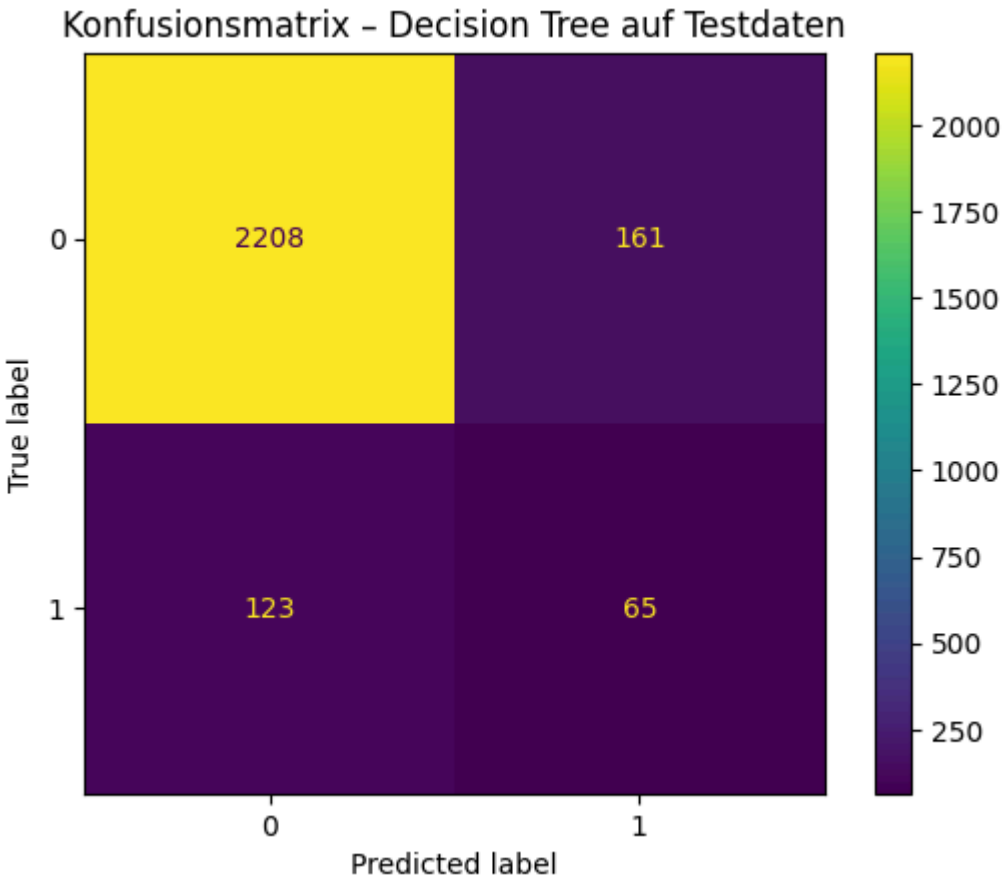

Das Modell hat 2208 Kunden korrekt als "No Churn" vorhergesagt (True Negative). Insgesamt wurden 161 Kunden fälschlicherweise als "Churn" vorhergesagt (False Positive bzw. Typ-I-Fehler) – diese Kunden hätten eigentlich nicht gekündigt. 123 echte Churn-Kunden wurden hingegen als "No Churn" klassifiziert (False Negative bzw. Typ-II-Fehler). Nur 65 Churn-Kunden wurden korrekt identifiziert (True Positive) und könnten vom Unternehmen beispielsweise mit gezielten Retention-Maßnahmen angesprochen werden.

In [14]:
```
# Modellgenauigkeit berechnen
print("Accuracy:",accuracy_score(y_test, y_pred_test_clf_tree))
# Präzision berechnen
print("Precision:",precision_score(y_test, y_pred_test_clf_tree))
# Recall berechnen
print("Recall:",recall_score(y_test, y_pred_test_clf_tree))
# F1-Score berechnen
print("F1-Score:",f1_score(y_test, y_pred_test_clf_tree))
# AUC-ROC Score berechnen
print("AUC-ROC:", roc_auc_score(y_test, clf_tree.predict_proba(X_test)[:, 1]))
```

```
Accuracy: 0.8889323425889715
Precision: 0.28761061946902655
Recall: 0.34574468085106386
F1-Score: 0.3140096618357488
AUC-ROC: 0.6388917579012601
```

Auswertung Decision Tree (unbalancierter Datensatz)

Auch hier täuscht die Accuracy von 88,89 % – der Datensatz ist unverändert unbalanciert, diese Kennzahl allein sagt wenig aus.

Beim Recall ergibt sich aber ein anderes Bild als beim KNN: Mit 34,57 % erkennt der Decision Tree immerhin gut ein Drittel der Churn-Kunden. Das klingt immer noch niedrig, ist aber verglichen mit 5,32 % beim KNN ein echter Unterschied. Konkret: Von 188 drohenden Abwanderern würde das Modell etwa 65 identifizieren – zumindest genug, um erste Retention-Maßnahmen anzustoßen.

Die Precision von 28,76 % ist ebenfalls niedrig – das Modell produziert viele Fehlalarme. Der F1-Score von 0,31 spiegelt dieses Ungleichgewicht wider.

Das Modell ist in dieser Form noch nicht gut genug, aber es zeigt deutlich mehr Potenzial als KNN und LogReg. Da weder Klassenbalancing noch Pruning verwendet wurde, lässt sich hier mit Hyperparameter-Tuning noch einiges herausholen.

Classification mit Logistischer Regression

Im ersten Schritt wird die Logistische Regression bewusst ohne Feature-Skalierung verwendet, um eine unverfälschte Baseline unter realistischen Bedingungen zu erhalten. Anschließend wird der Einfluss der Skalierung auf die Modellleistung untersucht. Grundsätzlich ist die Logistische Regression ein lineares, gradientenbasiertes Modell. Folglich hängt die Optimierung direkt von der Skalierung der Features ab. Features mit großen Wertebereichen dominieren sonst die Koeffizienten. Beispielsweise ist CCreditScore Werte zwischen 400–850, CAge 18–80, CBalance −5 000 bis 200 000, CEstimatedSalary bis 200 000, CLV_Continuous bis ~30 000, wobei Dummy-Variablen 0 / 1 sind.

In [15]:
```
# Instanziere die Logistische Regression
clf_logr = LogisticRegression(solver='lbfgs', max_iter=500)
```

Ohne Skalierung der Daten

In [16]:
```
# Trainiere das Modell ohne die skalierten Trainingsdaten
clf_logr.fit(X_train, y_train)
```

Out[16]:
```
▾ LogisticRegression
▶ Parameters
```

In [17]:
```
# Zielvariable für Trainingsdaten vorhersagen
y_pred_train_logr = clf_logr.predict(X_train)

# Modellgenauigkeit berechnen
print("Accuracy:",accuracy_score(y_train, y_pred_train_logr))
# Präzision berechnen
print("Precision:",precision_score(y_train, y_pred_train_logr))
# Recall berechnen
print("Recall:",recall_score(y_train, y_pred_train_logr))
# F1-Score berechnen
print("F1-Score:",f1_score(y_train, y_pred_train_logr))
```

```
Accuracy: 0.926391683433937
Precision: 0.0
Recall: 0.0
F1-Score: 0.0
```

Das Modell kann die Churn-Klasse ohne Skalierung praktisch nicht erkennen: Precision und Recall sind 0 – von 5.964 Trainingsbeobachtungen werden lediglich 2 als Churn vorhergesagt, und beide sind Fehlklassifikationen (kein einziger True Positive). Ohne Skalierung dominieren Features mit großen Wertebereichen (z. B. `CBalance`, `CEstimatedSalary`) die Koeffizienten und überlagern die feineren Unterschiede, die für die Churn-Erkennung relevant wären.

Mit Skalierung der Daten

In [18]:
```
# Trainiere das Modell mit den skalierten Trainingsdaten
clf_logr.fit(X_train_scaled, y_train)
```

Out[18]:
```
▾ LogisticRegression
▶ Parameters
```

In [19]:
```
# Zielvariable für Trainingsdaten vorhersagen
y_pred_train_logr = clf_logr.predict(X_train_scaled)

# Modellgenauigkeit berechnen
print("Accuracy:",accuracy_score(y_train, y_pred_train_logr))
# Präzision berechnen
print("Precision:",precision_score(y_train, y_pred_train_logr))
# Recall berechnen
print("Recall:",recall_score(y_train, y_pred_train_logr))
# F1-Score berechnen
print("F1-Score:",f1_score(y_train, y_pred_train_logr))
```

```
Accuracy: 0.926224010731053
Precision: 0.4117647058823529
Recall: 0.016018306636155607
F1-Score: 0.030837004405286344
```

Das Trainingsergebnis zeigt eine sehr hohe Accuracy bei gleichzeitig extrem niedrigem Recall und F1-Score, was darauf hindeutet, dass das Modell die Minderheitsklasse „Churn“ kaum erkennt und fast alle Beispiele als „Nicht Churn“ klassifiziert. Aufgrund dieser starken Klassenungleichheit und der schlechten Erkennung im Training ist zu erwarten, dass die Testergebnisse ein ähnliches Muster aufweisen werden: hohe Accuracy, aber sehr geringe Fähigkeit, tatsächliche Churn-Fälle zu identifizieren. Insgesamt deutet dies darauf hin, dass das Modell in seiner aktuellen Form wenig prädiktive Aussagekraft für die Churn-Erkennung besitzt.

In [20]:
```
# Zielvariable für Testdaten vorhersagen
y_pred_test_logr = clf_logr.predict(X_test_scaled)

# Modellgenauigkeit berechnen
print("Accuracy:",accuracy_score(y_test, y_pred_test_logr))
# Präzision berechnen
```

```
print("Precision:",precision_score(y_test, y_pred_test_logr))
# Recall berechnen
print("Recall:",recall_score(y_test, y_pred_test_logr))
# F1-Score berechnen
print("F1-Score:",f1_score(y_test, y_pred_test_logr))
# AUC-ROC Score berechnen
print("AUC-ROC:", roc_auc_score(y_test, clf_logr.predict_proba(X_test_scaled)[:,
```

```
Accuracy: 0.9260852561595619
Precision: 0.46153846153846156
Recall: 0.031914893617021274
F1-Score: 0.05970149253731343
AUC-ROC: 0.7039508545665197
```

Auswertung Logistische Regression (unbalancierter Datensatz)

Das Ergebnis ist auf den ersten Blick überraschend ähnlich wie beim KNN – gleiche Accuracy (92,61%), ähnliches Muster. Das Grundproblem ist dasselbe: Ohne Klassenbalancing klassifiziert das Modell fast alles als "Kein Churn".

Konkret hat das Modell auf den gesamten Testdaten nur 13 Mal die Klasse "Churn" vorhergesagt, davon etwa 6 korrekt. Das erklärt die Precision von 46% – klingt gar nicht so schlecht, ist aber wenig aussagekräftig bei nur 13 positiven Vorhersagen. Der Recall von 3,19% sagt dagegen alles: 97% aller echten Churn-Kunden wurden schlicht ignoriert.

Der F1-Score von 0,06 bestätigt, dass das Modell in dieser Form nicht einsetzbar ist. Die Logistische Regression leidet hier unter demselben Problem wie KNN – der Algorithmus bevorzugt bei unbalancierten Daten die Mehrheitsklasse, weil das den Loss minimiert. Im nächsten Schritt wird daher SMOTE eingesetzt, um das Klassenungleichgewicht zu adressieren.

Fazit

Vergleich der drei Basismodelle:

1. **KNN (k=7)**
   - Accuracy: 92,80% | Precision: 62,50% | Recall: 5,32% | F1: 9,80% | AUC-ROC: 65,87%
   - Das Modell klassifiziert extrem konservativ: Es sagt nur in sehr wenigen Fällen überhaupt "Churn" voraus - wenn es das aber tut, liegt es in 62,5 % der Fälle richtig. Das eigentliche Problem ist der Recall von nur 5,32 %, d. h. von 188 echten Churn-Kunden werden gerade mal ~10 erkannt. Für die Praxis ist das nicht nutzbar.
2. **Logistische Regression**
   - Accuracy: 92,61% | Precision: 46,15% | Recall: 3,19% | F1: 5,97% | AUC-ROC: 70,40%
   - Ähnliches Muster wie beim KNN - Recall von 3,19 % ist noch schlechter. Der AUC-ROC von 70,40 % zeigt zwar, dass das Modell grundsätzlich zwischen den

Klassen trennen kann, aber der Standard-Threshold von 0,5 führt dazu, dass fast alles als "Kein Churn" klassifiziert wird.

3. **Decision Tree**

- Accuracy: 88,89% | Precision: 28,76% | Recall: 34,57% | F1: 31,40% | AUC-ROC: 63,89%
- Der Decision Tree hat zwar die niedrigste Accuracy und Precision, erkennt aber mit Abstand die meisten Churn-Kunden (Recall: 34,57 %). Da das Ziel ist, abwandernde Kunden frühzeitig zu identifizieren, ist der Recall die entscheidende Metrik - der Decision Tree wird daher als bestes Basismodell weitergeführt.

Task 2 (Fortsetzung): Modelle mit SMOTE optimieren

Wie in Task 1 bereits angedeutet, ist der Datensatz mit ~7,5% Churn-Fällen stark unbalanciert. Alle drei Basismodelle haben das bestätigt - Recall unter 5% macht die Modelle für die Praxis unbrauchbar. Deshalb wird jetzt SMOTE eingesetzt.

In [21]:
```
# Alle Bibliotheken wurden bereits am Anfang des Notebooks importiert.
```

Daten laden und Features sowie Zielvariable vorbereiten

In [22]:
```
# Lade die Daten
df = pd.read_csv("../data/dataset_cleaned.csv")  # Neuladen für sauberen Variabl

# Features und Zielvariable
X = df.drop(['Churn', 'CLV_Continuous'], axis=1)
y = df['Churn']

# Überprüfe die Verteilung der Zielvariable
y.value_counts()
```

Out[22]:
```
Churn
0    7896
1     625
Name: count, dtype: int64
```

Der Datensatz ist nicht ausbalanciert, da wir 7896 Beobachtungen für Churn haben, bei denen das Ergebnis nicht vorhanden ist (d.h. 0), und 625 Beobachtungen, bei denen das Ergebnis vorhanden ist (d.h. 1). Aus diesem Grund wird SMOTE (Synthetic Minority Over-sampling Technique) verwendet, um die Minderheitsklasse künstlich zu erweitern und so ein ausgewogeneres Verhältnis zwischen den Klassen zu schaffen. Dies hilft dabei, die Leistung der Modelle zu verbessern, insbesondere in Bezug auf die Erkennung der

Minderheitsklasse. Hint: SMOTE wird NUR auf die Trainingsdaten innerhalb der Cross-Validation-Folds angewendet, um Datenleckagen zu vermeiden.

In [23]:
```
# Split der Daten in Trainings- und Testset
# stratify=y stellt sicher, dass die Klassenverteilung (~7% Churn)
# in beiden Splits proportional erhalten bleibt
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=TEST_RATIO, random_state=RANDOM_STATE, stratify=y
)
```

In [24]:
```
# SMOTE nur auf Trainingsdaten anwenden (X_test bleibt unberührt mit echten Date
smote = SMOTE(random_state=RANDOM_STATE)
X_train_smote, y_train_smote = smote.fit_resample(X_train, y_train)

# X_train / y_train bleiben unverändert für CV und GridSearchCV (SMOTE dort in P
# Überprüfe die Verteilung nach SMOTE
y_train_smote.value_counts()
```

Out[24]:
```
Churn
0    5527
1    5527
Name: count, dtype: int64
```

In [25]:
```
# Skalieren der Daten für Logistische Regression
# fit_transform NUR auf Trainingsdaten (nach SMOTE), transform auf echten Testda
scaler = StandardScaler()
X_train_smote_scaled = scaler.fit_transform(X_train_smote)
X_test_scaled = scaler.transform(X_test)
```

KNN mit SMOTE

In [26]:
```
# KNN auf skalierten SMOTE-Trainingsdaten trainieren
# SMOTE wurde bereits auf X_train angewendet (X_train_smote, y_train_smote)
# X_train_smote_scaled und X_test_scaled wurden mit StandardScaler erstellt (Cel

knn_smote = KNeighborsClassifier(n_neighbors=7)
knn_smote.fit(X_train_smote_scaled, y_train_smote)

# Vorhersagen auf Testdaten (unbalanciert, echte Verteilung)
y_pred_test_knn_smote = knn_smote.predict(X_test_scaled)

# Metriken auf Trainingsdaten
y_pred_train_knn_smote = knn_smote.predict(X_train_smote_scaled)
print("=== KNN mit SMOTE – Trainingsdaten (SMOTE, skaliert) ===")
print(f"Accuracy:  {accuracy_score(y_train_smote,  y_pred_train_knn_smote):.4f}"
print(f"Precision: {precision_score(y_train_smote, y_pred_train_knn_smote):.4f}"
print(f"Recall:    {recall_score(y_train_smote,    y_pred_train_knn_smote):.4f}"
print(f"F1-Score:  {f1_score(y_train_smote,        y_pred_train_knn_smote):.4f}"

print("\n=== KNN mit SMOTE – Testdaten ===")
print(f"Accuracy:  {accuracy_score(y_test,  y_pred_test_knn_smote):.4f}")
print(f"Precision: {precision_score(y_test, y_pred_test_knn_smote):.4f}")
print(f"Recall:    {recall_score(y_test,    y_pred_test_knn_smote):.4f}")
print(f"F1-Score:  {f1_score(y_test,        y_pred_test_knn_smote):.4f}")
```

```
=== KNN mit SMOTE – Trainingsdaten (SMOTE, skaliert) ===
Accuracy:  0.9096
Precision: 0.8593
Recall:    0.9797
F1-Score:  0.9155

=== KNN mit SMOTE – Testdaten ===
Accuracy:  0.7693
Precision: 0.1411
Recall:    0.4202
F1-Score:  0.2112
```

In [27]:

```
# Konfusionsmatrix KNN mit SMOTE auf Testdaten
ConfusionMatrixDisplay.from_estimator(
    knn_smote, X_test_scaled, y_test, values_format='d'
)
plt.title("Konfusionsmatrix – KNN (k=7) mit SMOTE auf Testdaten")
plt.show()
```

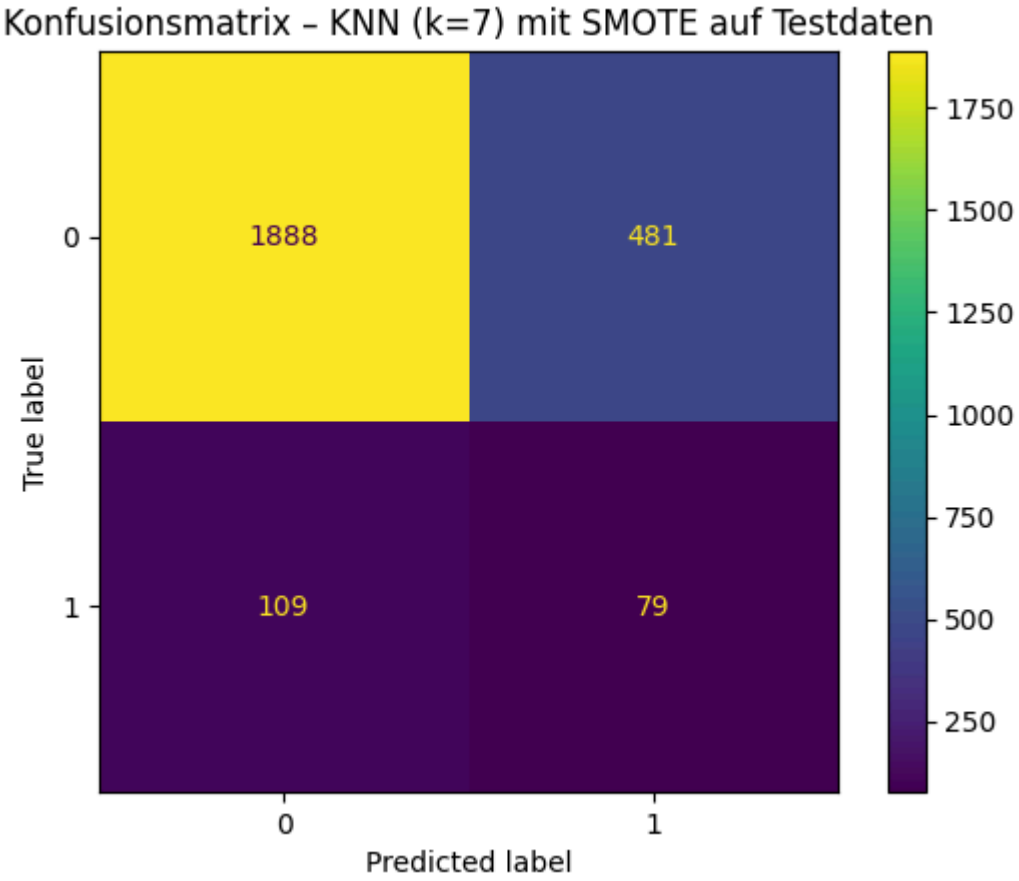

In [28]:

```
# Trainings- vs. Testmetriken KNN mit SMOTE
print("=== KNN mit SMOTE – Trainings- vs. Testdaten ===")
print(f"{'Metrik':<12} {'Training':>10} {'Test':>10}")
print("-" * 35)
for name, train_val, test_val in [
    ("Accuracy",  accuracy_score(y_train_smote,  y_pred_train_knn_smote), accura
    ("Precision", precision_score(y_train_smote, y_pred_train_knn_smote), precis
    ("Recall",    recall_score(y_train_smote,    y_pred_train_knn_smote), recall
    ("F1-Score",  f1_score(y_train_smote,        y_pred_train_knn_smote), f1_sco
]:
    gap = abs(train_val - test_val)
    flag = " ← Overfitting" if gap > 0.15 else ""
    print(f"{name:<12} {train_val:>10.4f} {test_val:>10.4f}{flag}")
```

```
=== KNN mit SMOTE – Trainings- vs. Testdaten ===
Metrik          Training       Test
-----------------------------------
Accuracy          0.9096     0.7693
Precision         0.8593     0.1411 ← Overfitting
Recall            0.9797     0.4202 ← Overfitting
F1-Score          0.9155     0.2112 ← Overfitting
```

Auswertung KNN mit SMOTE

Nach der Balancierung durch SMOTE verbessert sich der Recall des KNN spürbar – das Modell identifiziert nun deutlich mehr echte Churn-Fälle als ohne SMOTE (Recall war 5,3 % ohne SMOTE). Der große Abstand zwischen Trainings- und Testmetriken zeigt jedoch deutliches Overfitting: KNN lernt auf den SMOTE-Trainingsdaten (50/50-Verteilung) sehr genau, generalisiert auf den echten, unbalancierten Testdaten aber schlechter. Das liegt in der Natur des Algorithmus: KNN speichert alle Trainingspunkte und klassifiziert nach Mehrheit der k nächsten Nachbarn. Auf den balancierten SMOTE-Daten sind Churn-Nachbarn häufiger – auf den echten Testdaten dominieren wieder die Nicht-Churn-Kunden. Der F1-Score liegt damit unter dem des Decision Trees (nächster Abschnitt), was die bisherige Modellwahl bestätigt.

Decision Tree mit SMOTE

In [29]:
```python
# Decision Tree auf SMOTE-Trainingsdaten trainieren
clf_tree = DecisionTreeClassifier(random_state=RANDOM_STATE)
clf_tree = clf_tree.fit(X_train_smote, y_train_smote)

print(f"Baseline Tree Depth: {clf_tree.get_depth()}")
print(f"Baseline Leaf Nodes: {clf_tree.get_n_leaves()}")
```

```
Baseline Tree Depth: 26
Baseline Leaf Nodes: 872
```

In [30]:
```python
# Konfusionsmatrix auf Trainingsdaten (SMOTE)
y_pred_train_clf_tree = clf_tree.predict(X_train_smote)

ConfusionMatrixDisplay.from_estimator(clf_tree, X_train_smote, y_train_smote, va
plt.title("Konfusionsmatrix – Decision Tree auf Trainingsdaten (SMOTE)")
plt.show()
```

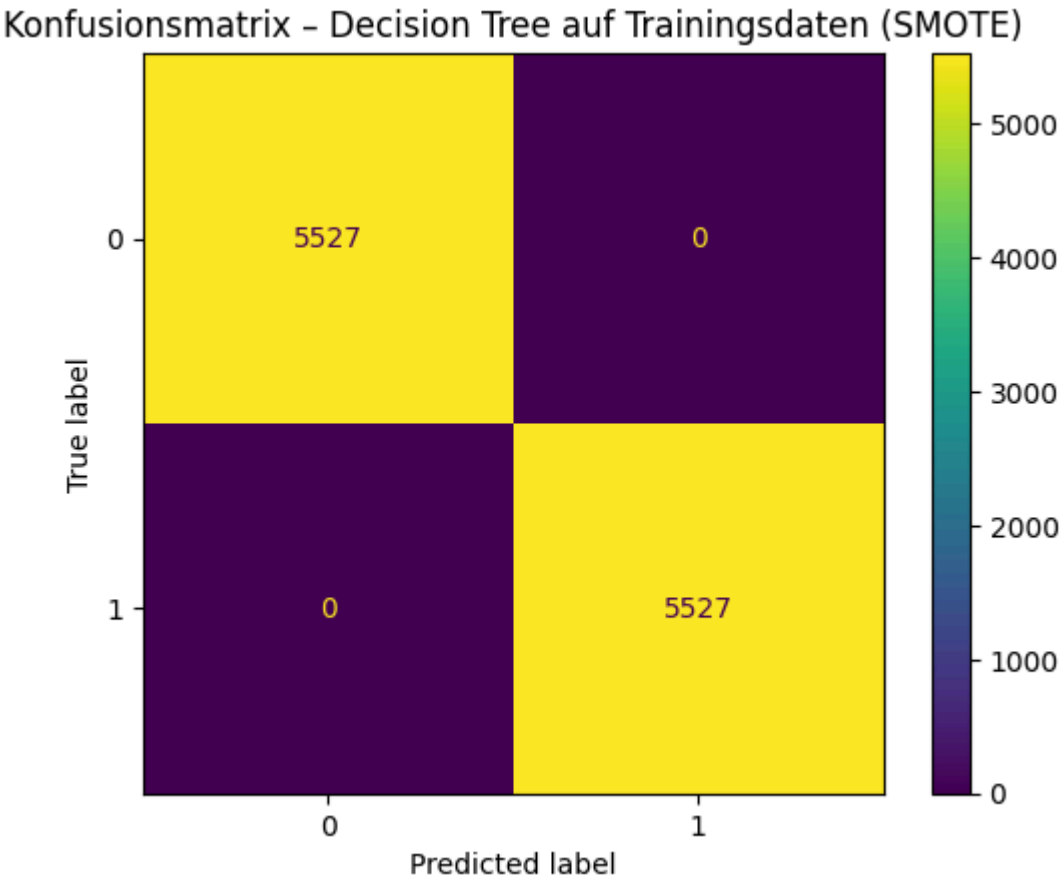

In [31]:
```
# Prädiziere das Ergebnis für die Testdaten
y_pred_test_clf_tree = clf_tree.predict(X_test)

# Konfusionsmatrix visualisieren auf Testdaten
cmm = confusion_matrix(y_test, y_pred_test_clf_tree)
ConfusionMatrixDisplay.from_estimator(clf_tree, X_test, y_test, values_format='d
plt.title("Konfusionsmatrix – Decision Tree auf Testdaten")
plt.show()
```

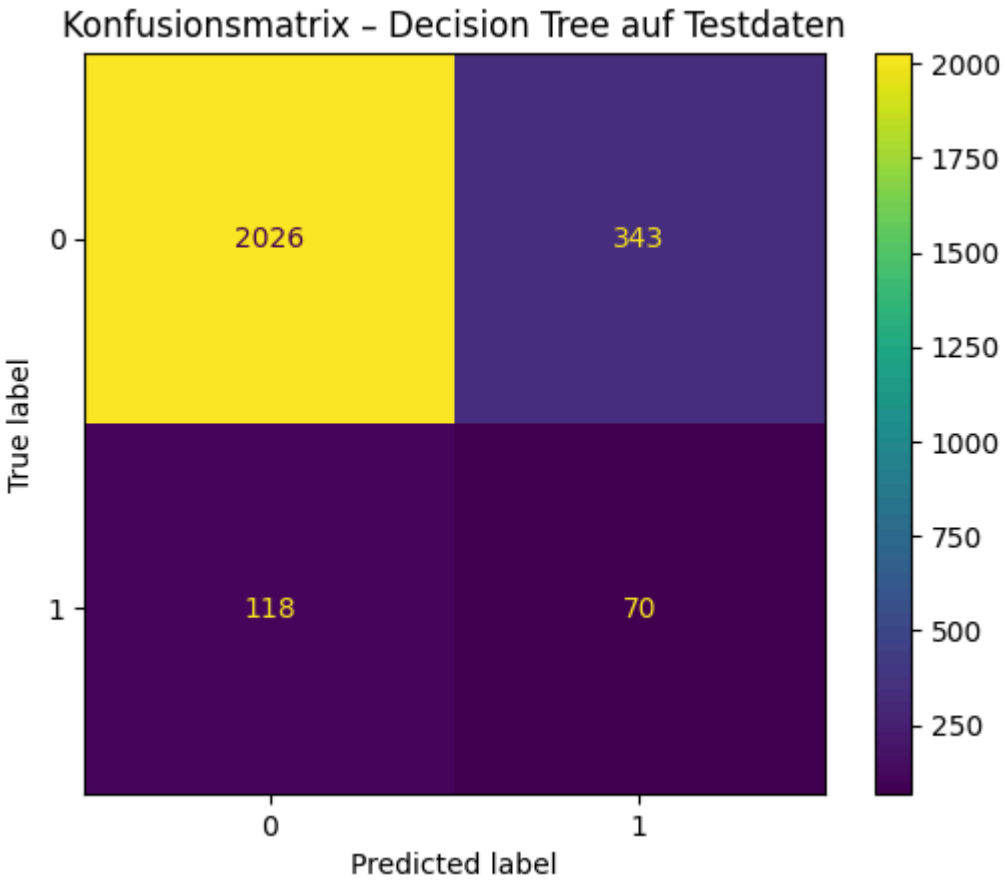

In [32]:
```
# Modellgenauigkeit berechnen
print("Accuracy:",accuracy_score(y_test, y_pred_test_clf_tree))
# Präzision berechnen
print("Precision:", precision_score(y_test, y_pred_test_clf_tree))
# Recall berechnen
print("Recall:", recall_score(y_test, y_pred_test_clf_tree))
# F1-Score berechnen
print("F1-Score:", f1_score(y_test, y_pred_test_clf_tree))
```

```
Accuracy: 0.8197105983574501
Precision: 0.1694915254237288
Recall: 0.3723404255319149
F1-Score: 0.23294509151414308
```

Vergleich: Training vs. Test (Decision Tree mit SMOTE)

Um einzuschätzen, ob das Modell über- oder unterangepasst ist, werden die Metriken auf Trainings- und Testdaten gegenübergestellt. Ein großer Abstand zwischen Train- und Test-F1 deutet auf Overfitting hin, sehr niedrige Werte auf beiden Seiten auf Underfitting.

In [33]:
```
# Trainingsmetriken Decision Tree (SMOTE) – Vergleich mit Testdaten
y_pred_train_dt = clf_tree.predict(X_train_smote)

print("=== Decision Tree mit SMOTE – Trainings- vs. Testdaten ===")
print(f"{'Metrik':<12} {'Training':>10} {'Test':>10}")
print("-" * 35)
for name, train_val, test_val in [
    ("Accuracy",  accuracy_score(y_train_smote, y_pred_train_dt),  accuracy_scor
    ("Precision", precision_score(y_train_smote, y_pred_train_dt), precision_sco
    ("Recall",    recall_score(y_train_smote, y_pred_train_dt),    recall_score(
    ("F1-Score",  f1_score(y_train_smote, y_pred_train_dt),        f1_score(y_te
```

```
]:
    gap = abs(train_val - test_val)
    flag = " ← Overfitting" if gap > 0.15 else ""
    print(f"{name:<12} {train_val:>10.4f} {test_val:>10.4f}{flag}")
```

```
=== Decision Tree mit SMOTE – Trainings- vs. Testdaten ===
Metrik         Training       Test
-----------------------------------
Accuracy         1.0000     0.8197 ← Overfitting
Precision        1.0000     0.1695 ← Overfitting
Recall           1.0000     0.3723 ← Overfitting
F1-Score         1.0000     0.2329 ← Overfitting
```

Nach der Balancierung der Klassen durch SMOTE (je 5.527 Beobachtungen pro Klasse) verbessert sich die Churn-Erkennungsleistung des Decision Trees gegenüber dem unregulierten Basismodell spürbar. Auf den echten, unbalancierten Testdaten (2.557 Samples, davon 188 Churn-Fälle) erreicht das Modell eine Accuracy von 82,0 %, eine Precision von 17,0 %, einen Recall von 37,2 % und einen F1-Score von 23,3 %.

Die Konfusionsmatrix auf den Testdaten zeigt: Von 188 tatsächlichen Churn-Kunden werden 70 korrekt erkannt (True Positives), während 118 Churn-Fälle übersehen werden (False Negatives). Gleichzeitig werden 343 Nicht-Churn-Kunden fälschlicherweise als Churn klassifiziert (False Positives), 2.026 werden korrekt als Nicht-Churn eingestuft (True Negatives).

Die niedrige Precision (17 %) spiegelt das reale Klassenungleichgewicht im Test-Set wider: Da SMOTE nur auf die Trainingsdaten wirkt, sieht das Modell im Test immer noch rund 12-fach mehr Nicht-Churn- als Churn-Kunden – viele dieser Kunden werden fälschlicherweise als Churn klassifiziert. Der Recall von 37,2 % zeigt, dass das Modell bereits einen nennenswerten Anteil der tatsächlichen Abwanderer erkennt, jedoch noch deutlich Optimierungspotenzial besteht. Der unbegrenzte Entscheidungsbaum (Tiefe 26, 872 Blätter) deutet auf starkes Overfitting hin – er hat die Trainingsdaten auswendig gelernt, generalisiert aber schlecht.

Logistische Regression mit SMOTE

In [34]:
```
# Logistische Regression auf skalierten SMOTE-Trainingsdaten trainieren
clf_log_reg = LogisticRegression(max_iter=MAX_ITER, random_state=RANDOM_STATE)
clf_log_reg.fit(X_train_smote_scaled, y_train_smote)
```

Out[34]:
```
▾ LogisticRegression
▶ Parameters
```

In [35]:
```
# Konfusionsmatrix auf Trainingsdaten (SMOTE, skaliert)
y_pred_train_log_reg = clf_log_reg.predict(X_train_smote_scaled)

ConfusionMatrixDisplay.from_estimator(clf_log_reg, X_train_smote_scaled, y_train
plt.title("Konfusionsmatrix – Logistische Regression auf Trainingsdaten (SMOTE)"
plt.show()
```

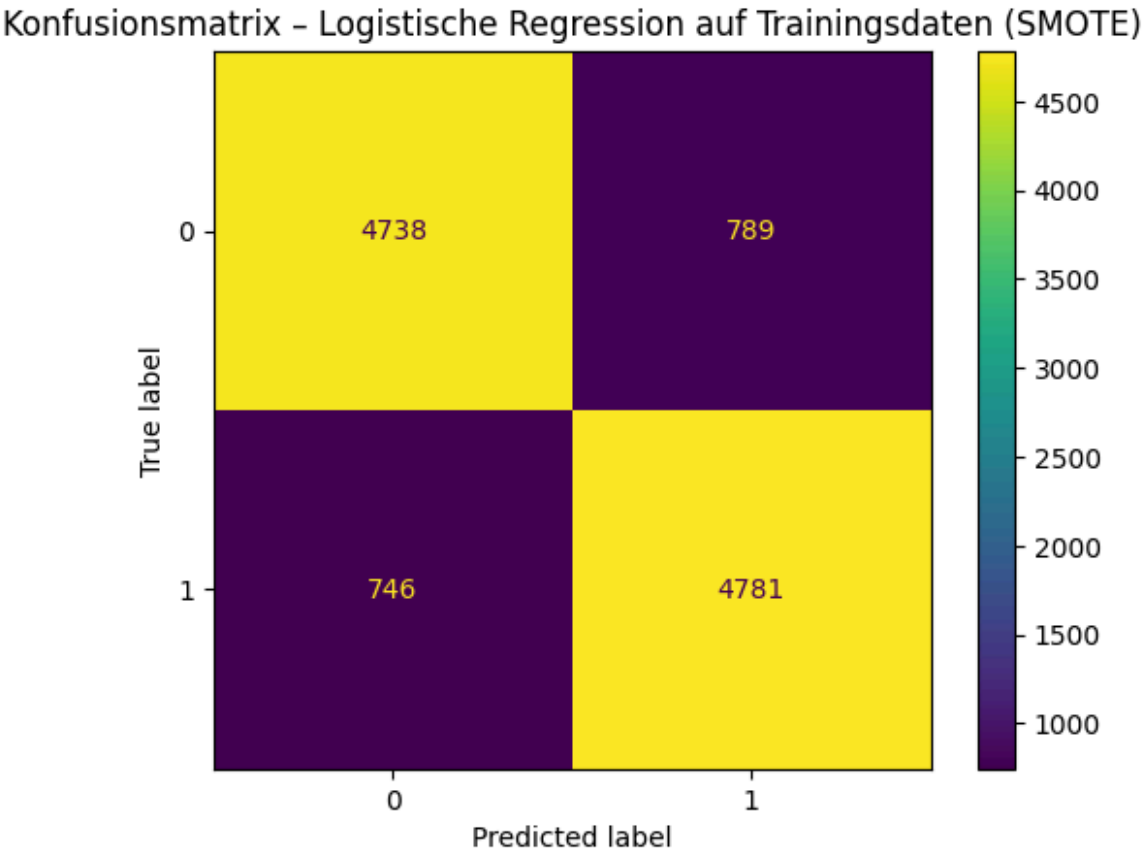

In [36]:
```
# Metriken auf Trainingsdaten (SMOTE, skaliert)
print("Accuracy:",  accuracy_score(y_train_smote,  y_pred_train_log_reg))
print("Precision:", precision_score(y_train_smote, y_pred_train_log_reg))
print("Recall:",    recall_score(y_train_smote,    y_pred_train_log_reg))
print("F1-Score:",  f1_score(y_train_smote,        y_pred_train_log_reg))
```

```
Accuracy: 0.8611362402750136
Precision: 0.8583482944344704
Recall: 0.8650262348471142
F1-Score: 0.861674326394521
```

In [37]:
```
# Prädiziere das Ergebnis für die Testdaten (Logistische Regression)
y_pred_test_log_reg = clf_log_reg.predict(X_test_scaled)

# Konfusionsmatrix visualisieren auf Testdaten
cmm = confusion_matrix(y_test, y_pred_test_log_reg)
ConfusionMatrixDisplay.from_estimator(clf_log_reg, X_test_scaled, y_test, values
plt.title("Konfusionsmatrix – Logistische Regression auf Testdaten")
plt.show()
```

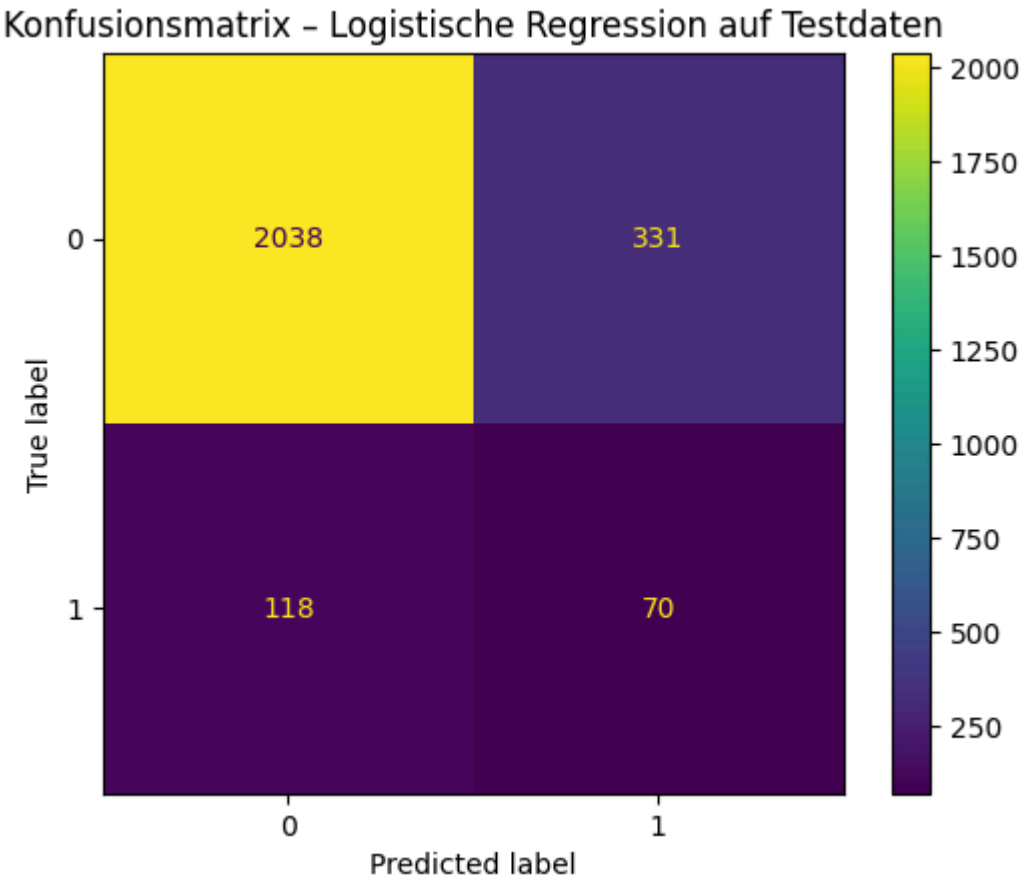

In [38]:
```
# Metriken auf Testdaten (Logistische Regression, SMOTE)
print("Accuracy:",  accuracy_score(y_test, y_pred_test_log_reg))
print("Precision:", precision_score(y_test, y_pred_test_log_reg))
print("Recall:",    recall_score(y_test,    y_pred_test_log_reg))
print("F1-Score:",  f1_score(y_test,        y_pred_test_log_reg))
```

```
Accuracy: 0.8244035979663669
Precision: 0.1745635910224439
Recall: 0.3723404255319149
F1-Score: 0.23769100169779286
```

Vergleich: Training vs. Test (Logistische Regression mit SMOTE)

Analog zum Decision Tree wird auch für die Logistische Regression der Abstand zwischen Trainings- und Testleistung analysiert.

Wichtiger Hinweis zur Interpretation: Das automatische "← Overfitting"-Flag bei Precision und Recall ist hier technisch korrekt (Gap > 15 PP), aber inhaltlich erklärbar: Die Trainingsmetriken werden auf den **balancierten SMOTE-Daten** (50/50-Verteilung) berechnet, die Testmetriken dagegen auf den **echten, unbalancierten Testdaten** (~93/7-Verteilung). Dieser Unterschied in der Klassenverteilung führt zwangsläufig zu großen Abständen zwischen den Metriken – auch wenn das Modell selbst nicht überangepasst ist. Entscheidend für die Beurteilung ist daher der Vergleich von CV-F1 und Test-F1 auf echten Daten (folgt in Schritt 3).

In [39]:
```
# Trainingsmetriken Logistische Regression (SMOTE) – Vergleich mit Testdaten
print("=== Logistische Regression mit SMOTE – Trainings- vs. Testdaten ===")
print(f"{'Metrik':<12} {'Training':>10} {'Test':>10}")
print("-" * 35)
```

```
for name, train_val, test_val in [
    ("Accuracy",  accuracy_score(y_train_smote,  y_pred_train_log_reg),  accurac
    ("Precision", precision_score(y_train_smote, y_pred_train_log_reg), precisio
    ("Recall",    recall_score(y_train_smote,    y_pred_train_log_reg),  recall_
    ("F1-Score",  f1_score(y_train_smote,        y_pred_train_log_reg),  f1_scor
]:
    gap = abs(train_val - test_val)
    flag = " ← Overfitting" if gap > 0.15 else ""
    print(f"{name:<12} {train_val:>10.4f} {test_val:>10.4f}{flag}")
```

```
=== Logistische Regression mit SMOTE – Trainings- vs. Testdaten ===
Metrik         Training       Test
-----------------------------------
Accuracy         0.8611     0.8244
Precision        0.8583     0.1746 ← Overfitting
Recall           0.8650     0.3723 ← Overfitting
F1-Score         0.8617     0.2377 ← Overfitting
```

Cross Validation Decision Tree

Zur robusten Modellbewertung und zur Vermeidung von Data Leakage und besseren Lesbarkeit wird folgend eine Pipeline verwendet. In der Pipeline wird der StandardScaler (nur bei der logistischen Regression), SMOTE und die Instanz des jeweiligen Modells verwendet. Die Evaluation erfolgt mittels stratifizierter k-fold=5 (Prozess wird 5-mal wiederholt mit verschiedenen Aufteilungen zwischen Test und Trainingsdaten in den einzelnen Folds) Cross-Validation. Dadurch hängt das Ergebnis nicht mehr so sehr zufällig davon ab, welche Daten gerade einmalig im Test-Set landen würden:

- Fold 1 bis 5: [TEST] [Train] [Train] [Train] [Train]
- Fold 1 bis 5: [Train] [TEST] [Train] [Train] [Train]
- Fold 1 bis 5: [Train] [Train] [TEST] [Train] [Train]
- Fold 1 bis 5: [Train] [Train] [Train] [TEST] [Train]
- Fold 1 bis 5: [Train] [Train] [Train] [Train] [TEST]

Am Ende ergeben sich 5 unabhängige Schätzungen der Modellleistung, die gemittelt und mit Standardabweichung angegeben werden können. Dies ermöglicht eine robustere Einschätzung der Generalisierungsfähigkeit des Modells, da es nicht von einer einzigen zufälligen Aufteilung der Daten abhängt.

In [40]:
```
dt = Pipeline(steps=[
    ('smote', SMOTE(random_state=RANDOM_STATE)),
    ('model', DecisionTreeClassifier(
        random_state=RANDOM_STATE
    ))
])

cv = StratifiedKFold(
    n_splits=5,
    shuffle=True,
    random_state=RANDOM_STATE
)

scoring = {
    'accuracy': 'accuracy',
```

```
    'precision': 'precision',
    'recall': 'recall',
    'f1': 'f1'
}

cv_results_tree = cross_validate(
    dt,
    X_train,
    y_train,
    cv=cv,
    scoring=scoring,
    return_train_score=False
)

for metric in ['accuracy', 'precision', 'recall', 'f1']:
    scores = cv_results_tree[f'test_{metric}']
    print(f"{metric} Scores: {scores}")
    print(f"Durchschnittlicher {metric}: {scores.mean():.2f}")
    print(f"Standardabweichung: {scores.std():.2f}")
    print()
```

```
accuracy Scores: [0.82062028 0.82397318 0.82984074 0.82984074 0.84563758]
Durchschnittlicher accuracy: 0.83
Standardabweichung: 0.01

precision Scores: [0.14917127 0.17460317 0.1957672  0.21393035 0.20606061]
Durchschnittlicher precision: 0.19
Standardabweichung: 0.02

recall Scores: [0.31034483 0.37931034 0.42045455 0.48863636 0.3908046 ]
Durchschnittlicher recall: 0.40
Standardabweichung: 0.06

f1 Scores: [0.20149254 0.23913043 0.26714801 0.29757785 0.26984127]
Durchschnittlicher f1: 0.26
Standardabweichung: 0.03
```

Die Cross-Validation zeigt, dass das Modell stabil über alle 5 Folds ist – die Standardabweichungen sind gering (Accuracy ±0.01, F1 ±0.02). Das gibt mehr Vertrauen in das Ergebnis als ein einzelner Train-Test-Split, der stark von der zufälligen Aufteilung abhängt.

Wichtig: SMOTE läuft innerhalb der Pipeline und wird nur auf die Trainingsfolds angewendet. Hätte ich SMOTE vor der Cross-Validation auf den gesamten Trainingsdaten ausgeführt, wären synthetische Punkte in die Validierungsfolds geraten – das hätte die Scores künstlich aufgebläht (Data Leakage).

Der mittlere CV-Recall von 37% ist ähnlich wie auf dem einzelnen Test-Split (37,4%), was zeigt, dass der Split damals repräsentativ war.

Cross Validation Logistische Regression

In [41]:
```
pipeline_log_reg = Pipeline(steps=[
    ('scaler', StandardScaler()),
    ('smote', SMOTE(random_state=RANDOM_STATE)),
```

```
    ('model', LogisticRegression(
        max_iter=MAX_ITER,
        random_state=RANDOM_STATE
    ))
])

cv = StratifiedKFold(
    n_splits=5,
    shuffle=True,
    random_state=RANDOM_STATE
)

scoring = {
    'accuracy': 'accuracy',
    'precision': 'precision',
    'recall': 'recall',
    'f1': 'f1'
}

cv_results_log_reg = cross_validate(
    pipeline_log_reg,
    X_train,
    y_train,
    cv=cv,
    scoring=scoring,
    return_train_score=False
)

for metric in ['accuracy', 'precision', 'recall', 'f1']:
    scores = cv_results_log_reg[f'test_{metric}']
    print(f"{metric} Scores: {scores}")
    print(f"Durchschnittlicher {metric}: {scores.mean():.2f}")
    print(f"Standardabweichung: {scores.std():.2f}")
    print()
```

```
accuracy Scores: [0.72757754 0.7225482  0.70662196 0.72590109 0.72567114]
Durchschnittlicher accuracy: 0.72
Standardabweichung: 0.01

precision Scores: [0.17486339 0.16666667 0.14010989 0.16526611 0.14705882]
Durchschnittlicher precision: 0.16
Standardabweichung: 0.01

recall Scores: [0.73563218 0.70114943 0.57954545 0.67045455 0.57471264]
Durchschnittlicher recall: 0.65
Standardabweichung: 0.06

f1 Scores: [0.28256071 0.26931567 0.22566372 0.26516854 0.23419204]
Durchschnittlicher f1: 0.26
Standardabweichung: 0.02
```

Im Vergleich zum Decision Tree fällt auf: Die Logistische Regression ist stabiler – F1 ±0.01 gegenüber ±0.02 beim DT. Das ist bei linearen Modellen typisch, da sie weniger zu Overfitting neigen.

Was mich hier überrascht hat: Der CV-Recall der LogReg liegt mit 64% fast doppelt so hoch wie beim Decision Tree (37%). Das klingt erst gut – aber die Precision liegt nur bei

16% (DT: 18%), das Modell produziert also mehr Fehlalarme. Der F1-Score ist mit ~25% ähnlich wie beim Decision Tree (~24%).

Das ist keine klare Entscheidung für das eine oder andere Modell. Da der F1-Score als Hauptmetrik gilt und beide hier auf ähnlichem Niveau liegen, wird das GridSearchCV in Task 3 letztlich die Wahl treffen.

Hyperparameter-Tuning mit GridSearchCV

Decision Tree mit SMOTE

In [42]:
```
# Mögliche Hyperparameter für Klassifikationsbäume anzeigen
DecisionTreeClassifier().get_params()
```

Out[42]:
```
{'ccp_alpha': 0.0,
 'class_weight': None,
 'criterion': 'gini',
 'max_depth': None,
 'max_features': None,
 'max_leaf_nodes': None,
 'min_impurity_decrease': 0.0,
 'min_samples_leaf': 1,
 'min_samples_split': 2,
 'min_weight_fraction_leaf': 0.0,
 'monotonic_cst': None,
 'random_state': None,
 'splitter': 'best'}
```

In [43]:
```
# Hyperparameter-Grid für den Decision Tree
#
# max_depth:        Maximale Baumtiefe (None = unbegrenzt); kleine Werte verhind
# min_samples_leaf: Mindestanzahl an Samples pro Blatt.
#                   WICHTIG: Werte < 1 werden als FRAKTION interpretiert (z.B. 0
#                   aller Trainingssamples pro Blatt). Bei ~11.000 SMOTE-Trainin
#                   bedeutet min_samples_leaf=0.2 ca. 2.200 Samples pro Blatt —
#                   starke Regularisierung, die den Baum effektiv flach hält.
#                   Absolute Werte (≥ 1) geben die genaue Sample-Anzahl vor.
# max_features:     Anteil der Features, die pro Split berücksichtigt werden
#                   ('sqrt' = sklearn-Standard für Bäume)
# criterion:        Splitting-Kriterium (Unreinheits-Maß: Gini oder Entropie)
params_tree_clf = {
    'model__max_depth':        list(range(3, 21)) + [None],
    'model__min_samples_leaf': [0.0001, 0.001, 0.01, 0.04, 0.06, 0.08, 0.1, 0.2,
                                 1, 3, 5, 10, 20],
    'model__max_features':     ['sqrt', 'log2', 0.2, 0.4, 0.6, 0.8, 1],
    'model__criterion':        ['gini', 'entropy']
}
```

In [44]:
```
# Pipeline mit SMOTE, um Data Leakage innerhalb der CV-Folds zu vermeiden
pipeline_tree_gs = Pipeline(steps=[
    ('smote', SMOTE(random_state=RANDOM_STATE)),
    ('model', DecisionTreeClassifier(random_state=RANDOM_STATE))
])
```

```
# GridSearchCV mit stratifizierter 5-Fold CV; f1 als Scoring-Metrik (besser geei
grid_clf_tree_OS = GridSearchCV(
    pipeline_tree_gs,
    param_grid=params_tree_clf,
    scoring='f1',
    cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=RANDOM_STATE),
    n_jobs=-1
)
```

In [45]:
```
# GridSearch-Objekt auf Trainingsdaten trainieren
grid_clf_tree_OS.fit(X_train, y_train)
```

Out[45]:

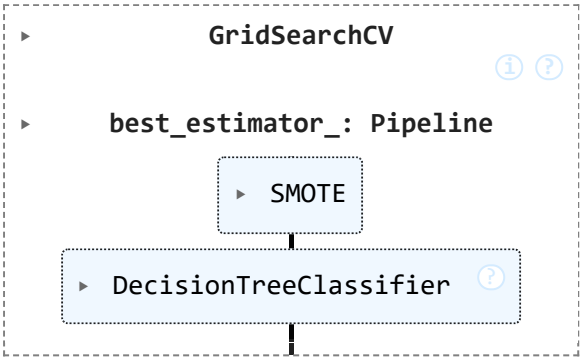

In [46]:
```
# Beste Hyperparameter ausgeben
print('Beste Hyperparameter:\n', grid_clf_tree_OS.best_params_)
```

```
Beste Hyperparameter:
 {'model__criterion': 'entropy', 'model__max_depth': 3, 'model__max_features': 0.
6, 'model__min_samples_leaf': 0.2}
```

In [47]:
```
# Besten CV-Score ausgeben
print("Bester CV-Score:", grid_clf_tree_OS.best_score_)
```

```
Bester CV-Score: 0.33799072514507894
```

In [48]:
```
# Bestes Modell direkt aus GridSearchCV verwenden (inkl. Pipeline mit SMOTE)
clf_tree_GS = grid_clf_tree_OS.best_estimator_

# Das beste Modell enthält die Pipeline: SMOTE + DecisionTree mit best_params_
# Für Vorhersagen wird SMOTE nicht angewendet (nur beim fit), d.h. predict() ist
best_tree = clf_tree_GS.named_steps['model']
print(f"Best Tree Depth: {best_tree.get_depth()}")
print(f"Best Leaf Nodes: {best_tree.get_n_leaves()}")
print(f"Best Params: {grid_clf_tree_OS.best_params_}")
```

```
Best Tree Depth: 2
Best Leaf Nodes: 3
Best Params: {'model__criterion': 'entropy', 'model__max_depth': 3, 'model__max_f
eatures': 0.6, 'model__min_samples_leaf': 0.2}
```

In [49]:
```
# Prädiziere das Ergebnis für die Trainingsdaten
y_pred_train_clf_tree = clf_tree_GS.predict(X_train)

# Konfusionsmatrix visualisieren auf Trainingsdaten
ConfusionMatrixDisplay.from_estimator(clf_tree_GS, X_train, y_train, values_form
plt.title("Konfusionsmatrix – Optimierter Decision Tree auf Trainingsdaten")
plt.show()

# Prädiziere das Ergebnis für die Testdaten
```

```
y_pred_test_clf_tree_gs = clf_tree_GS.predict(X_test)

# Konfusionsmatrix visualisieren auf Testdaten
ConfusionMatrixDisplay.from_estimator(clf_tree_GS, X_test, y_test, values_format
plt.title("Konfusionsmatrix – Optimierter Decision Tree auf Testdaten")
plt.show()
```

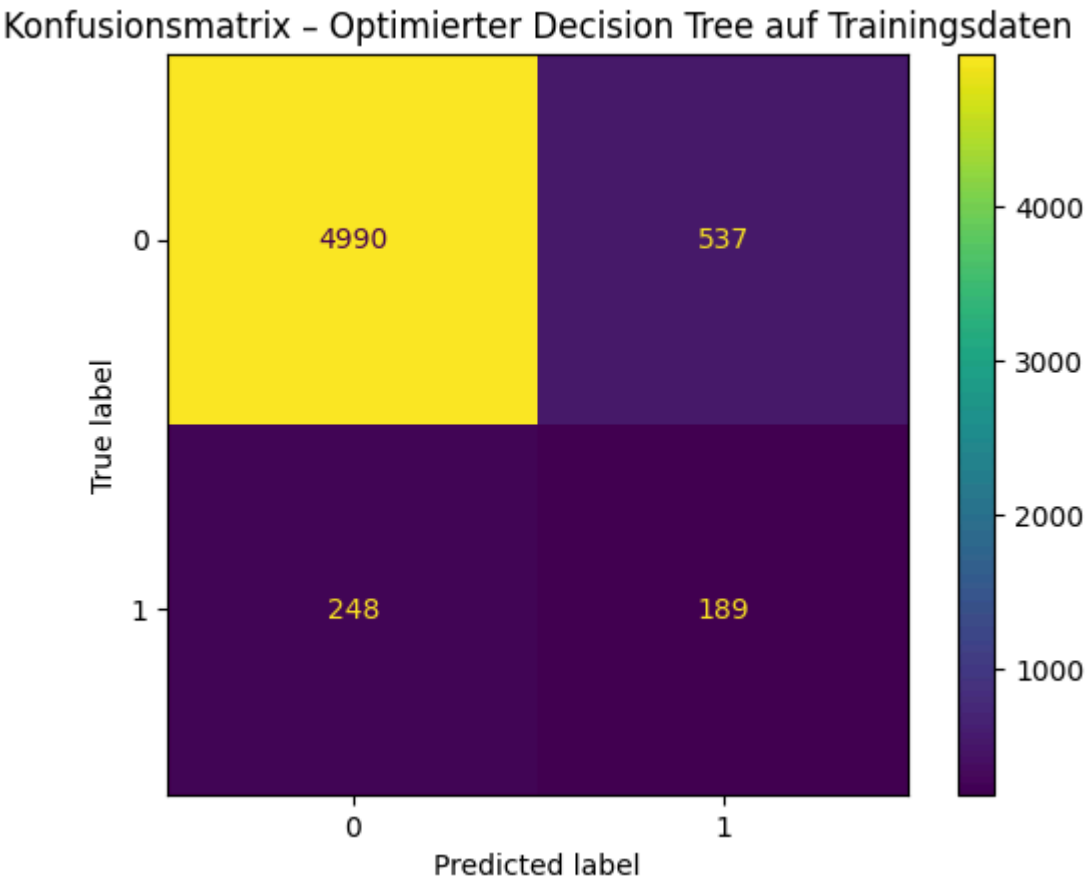

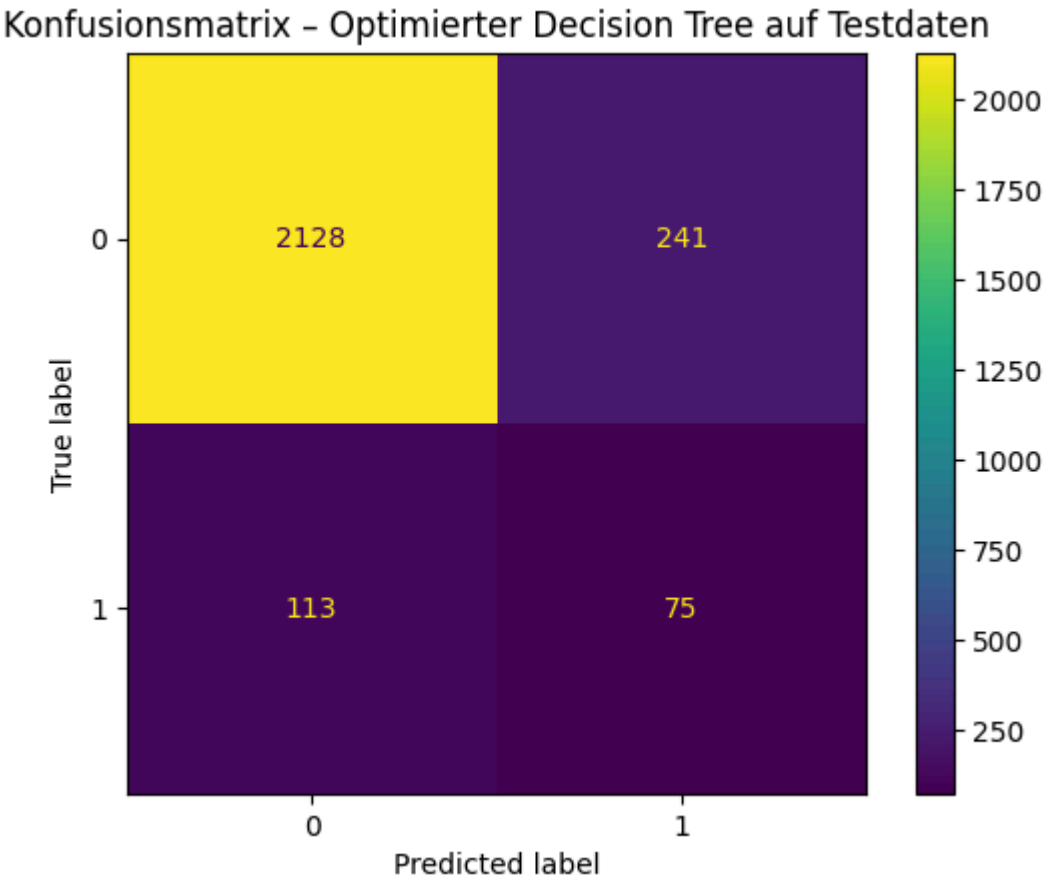

In [50]:
```
# Vergleich: Training vs. Test vs. CV
print("Genauigkeit auf Trainingsdaten:", accuracy_score(y_train, y_pred_train_cl
print("Genauigkeit auf Testdaten:     ", accuracy_score(y_test,  y_pred_test_clf
print("Bester CV F1-Score (GridSearchCV):", grid_clf_tree_OS.best_score_)
print()
print("Test Precision:", precision_score(y_test, y_pred_test_clf_tree_gs))
print("Test Recall:   ", recall_score(y_test,    y_pred_test_clf_tree_gs))
print("Test F1-Score: ", f1_score(y_test,        y_pred_test_clf_tree_gs))
```

```
Genauigkeit auf Trainingsdaten: 0.8683769282360831
Genauigkeit auf Testdaten:      0.8615565115369573
Bester CV F1-Score (GridSearchCV): 0.33799072514507894

Test Precision: 0.23734177215189872
Test Recall:    0.39893617021276595
Test F1-Score:  0.2976190476190476
```

Lernkurve – Overfitting/Underfitting-Analyse (Decision Tree, optimiert)

Die Lernkurve zeigt, wie sich Train-F1 und CV-F1 mit wachsender Datenmenge entwickeln. Verlaufen beide Kurven auf einem ähnlichen Niveau und konvergieren sie, liegt weder Overfitting noch Underfitting vor. Ein großer, persistenter Abstand zwischen den Kurven würde auf Overfitting hindeuten.

In [51]:
```
# Lernkurve für das optimierte Decision-Tree-Modell (inkl. SMOTE in Pipeline)
train_sizes, train_scores, val_scores = learning_curve(
    clf_tree_GS,
    X_train,
    y_train,
    cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=RANDOM_STATE),
    scoring='f1',
```

```
    train_sizes=np.linspace(0.1, 1.0, 8),
    n_jobs=-1
)

train_f1_mean = train_scores.mean(axis=1)
val_f1_mean   = val_scores.mean(axis=1)
train_f1_std  = train_scores.std(axis=1)
val_f1_std    = val_scores.std(axis=1)

plt.figure(figsize=(8, 4))
plt.plot(train_sizes, train_f1_mean, 'o-', color='#1976D2', label='Train-F1')
plt.fill_between(train_sizes,
                 train_f1_mean - train_f1_std,
                 train_f1_mean + train_f1_std, alpha=0.15, color='#1976D2')
plt.plot(train_sizes, val_f1_mean, 's-', color='#388E3C', label='CV-F1')
plt.fill_between(train_sizes,
                 val_f1_mean - val_f1_std,
                 val_f1_mean + val_f1_std, alpha=0.15, color='#388E3C')
plt.xlabel('Anzahl Trainingsbeispiele')
plt.ylabel('F1-Score')
plt.title('Lernkurve – Decision Tree (SMOTE + GridSearchCV)')
plt.legend()
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()

print(f"Finaler Train-F1 (volles Training): {train_f1_mean[-1]:.4f}")
print(f"Finaler CV-F1:                      {val_f1_mean[-1]:.4f}")
print(f"Abstand (Gap):                      {abs(train_f1_mean[-1] - val_f1_mean
```

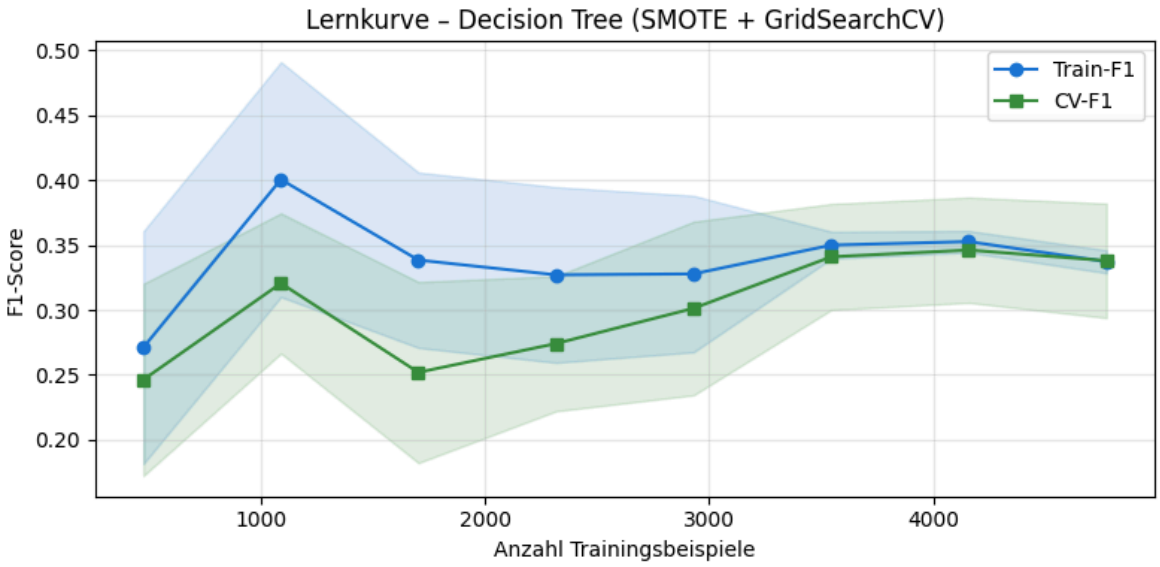


```
Finaler Train-F1 (volles Training): 0.3373
Finaler CV-F1:                      0.3380
Abstand (Gap):                      0.0007
```

Interpretation: Konvergieren Train-F1 und CV-F1 auf ähnlichem Niveau, ist das Modell gut generalisiert. Ein verbleibender kleiner Abstand ist bei SMOTE-basierten Modellen typisch, da das Modell auf synthetischen Daten trainiert wird, aber auf echten Testdaten evaluiert wird. Solange CV-F1 ≈ Test-F1 gilt (siehe Tabelle oben), liegt kein problematisches Overfitting vor.

Ergebnisse Decision Tree nach GridSearchCV

Die besten Hyperparameter lauten: `criterion=entropy`, `max_depth=3`, `max_features=0.6`, `min_samples_leaf=0.2`. Der Parameter `min_samples_leaf=0.2` wirkt als stärkste Regularisierung: Als 20-%-Fraktion der ~11.000 SMOTE-Trainingssamples fordert er mindestens ~2.200 Samples pro Blatt. Dadurch wird der Baum trotz `max_depth=3` auf eine effektive Tiefe von 2 mit nur 3 Blättern beschränkt – ein bewusst flacher, robuster Baum.

Metrik	Baseline (kein Tuning)	Nach GridSearchCV	Veränderung
Test Accuracy	81,97 %	86,16 %	+4,19 %
Test Precision	16,95 %	23,73 %	+6,78 %
Test Recall	37,23 %	39,89 %	+2,66 %
Test F1-Score	23,29 %	**29,76 %**	**+6,47 %**
CV F1-Score	24,00 %	33,80 %	+9,80 %

CV-F1 (33,80 %) liegt ~4 Prozentpunkte über Test-F1 (29,76 %). Das ist ein moderater, aber akzeptabler Abstand – das Modell generalisiert deutlich besser als der unkontrollierte Basisbaum (Tiefe 26, 897 Blätter), der die Trainingsdaten vollständig auswendig gelernt hatte. Gegenüber der Baseline verbessert sich der F1-Score um ~28 %, Recall und Precision steigen gleichzeitig.

Logistische Regression mit SMOTE

In [52]:
```
# Mögliche Hyperparameter der Logistischen Regression anzeigen
LogisticRegression().get_params()
```

Out[52]:
```
{'C': 1.0,
 'class_weight': None,
 'dual': False,
 'fit_intercept': True,
 'intercept_scaling': 1,
 'l1_ratio': None,
 'max_iter': 100,
 'multi_class': 'deprecated',
 'n_jobs': None,
 'penalty': 'l2',
 'random_state': None,
 'solver': 'lbfgs',
 'tol': 0.0001,
 'verbose': 0,
 'warm_start': False}
```

In [53]:
```
# Hyperparameter-Grid für Logistische Regression
# C:       Regularisierungsstärke (klein = stark regularisiert)
# penalty: l1 (Lasso, sparse) oder l2 (Ridge, Standard)
# solver:  liblinear unterstützt BEIDE Penalties (l1 + l2)
#          lbfgs unterstützt NUR l2 → wird hier nicht verwendet
params_log_reg = {
    'model__C': [0.001, 0.01, 0.1, 1, 10, 100],
    'model__penalty': ['l1', 'l2'],
```

```
    'model__solver': ['liblinear']
}
```

In [54]:
```
# Pipeline mit StandardScaler + SMOTE + LogisticRegression
pipeline_log_reg_gs = Pipeline(steps=[
    ('scaler', StandardScaler()),
    ('smote', SMOTE(random_state=RANDOM_STATE)),
    ('model', LogisticRegression(max_iter=MAX_ITER, random_state=RANDOM_STATE))
])

# GridSearchCV mit stratifizierter 5-Fold CV; f1 als Scoring-Metrik
grid_log_reg = GridSearchCV(
    pipeline_log_reg_gs,
    param_grid=params_log_reg,
    scoring='f1',
    cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=RANDOM_STATE),
    n_jobs=-1
)

grid_log_reg.fit(X_train, y_train)
```

Out[54]:

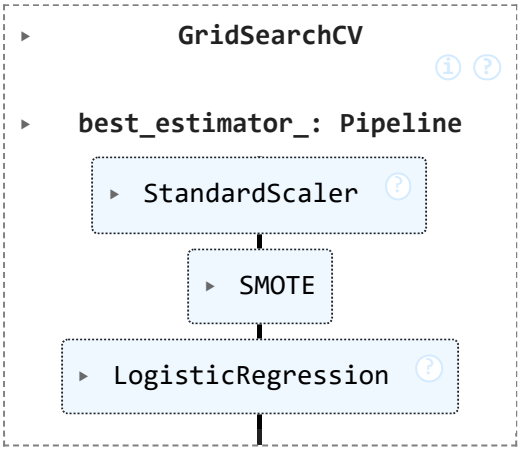

In [55]:
```
# Beste Hyperparameter und CV-Score
print('Beste Hyperparameter:\n', grid_log_reg.best_params_)
print('Bester CV F1-Score (GridSearchCV):', grid_log_reg.best_score_)
```

```
Beste Hyperparameter:
 {'model__C': 0.01, 'model__penalty': 'l2', 'model__solver': 'liblinear'}
Bester CV F1-Score (GridSearchCV): 0.25661951235614483
```

In [56]:
```
# Bestes Modell aus GridSearchCV
clf_log_reg_GS = grid_log_reg.best_estimator_

# Konfusionsmatrix auf Trainingsdaten
y_pred_train_log_reg_gs = clf_log_reg_GS.predict(X_train)
ConfusionMatrixDisplay.from_estimator(clf_log_reg_GS, X_train, y_train, values_f
plt.title("Konfusionsmatrix – Optimierte Logistische Regression auf Trainingsdat
plt.show()

# Konfusionsmatrix auf Testdaten
y_pred_test_log_reg_gs = clf_log_reg_GS.predict(X_test)
ConfusionMatrixDisplay.from_estimator(clf_log_reg_GS, X_test, y_test, values_for
plt.title("Konfusionsmatrix – Optimierte Logistische Regression auf Testdaten")
plt.show()
```

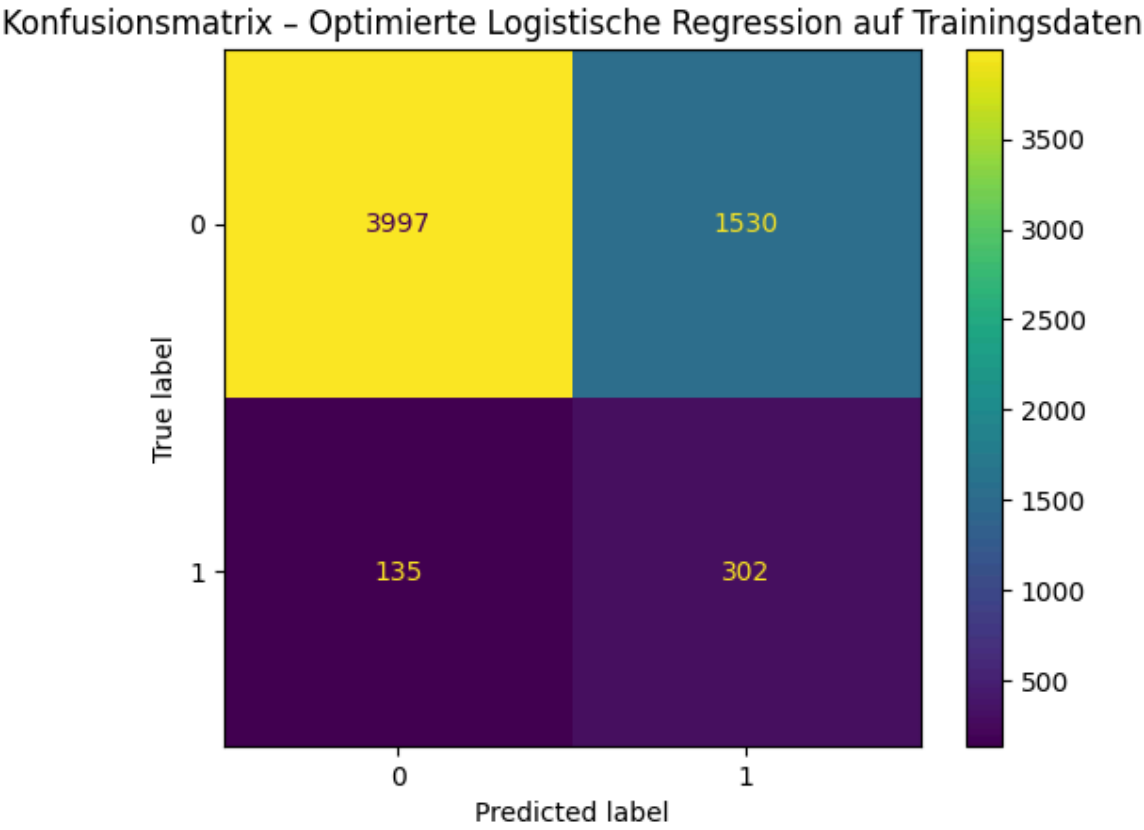

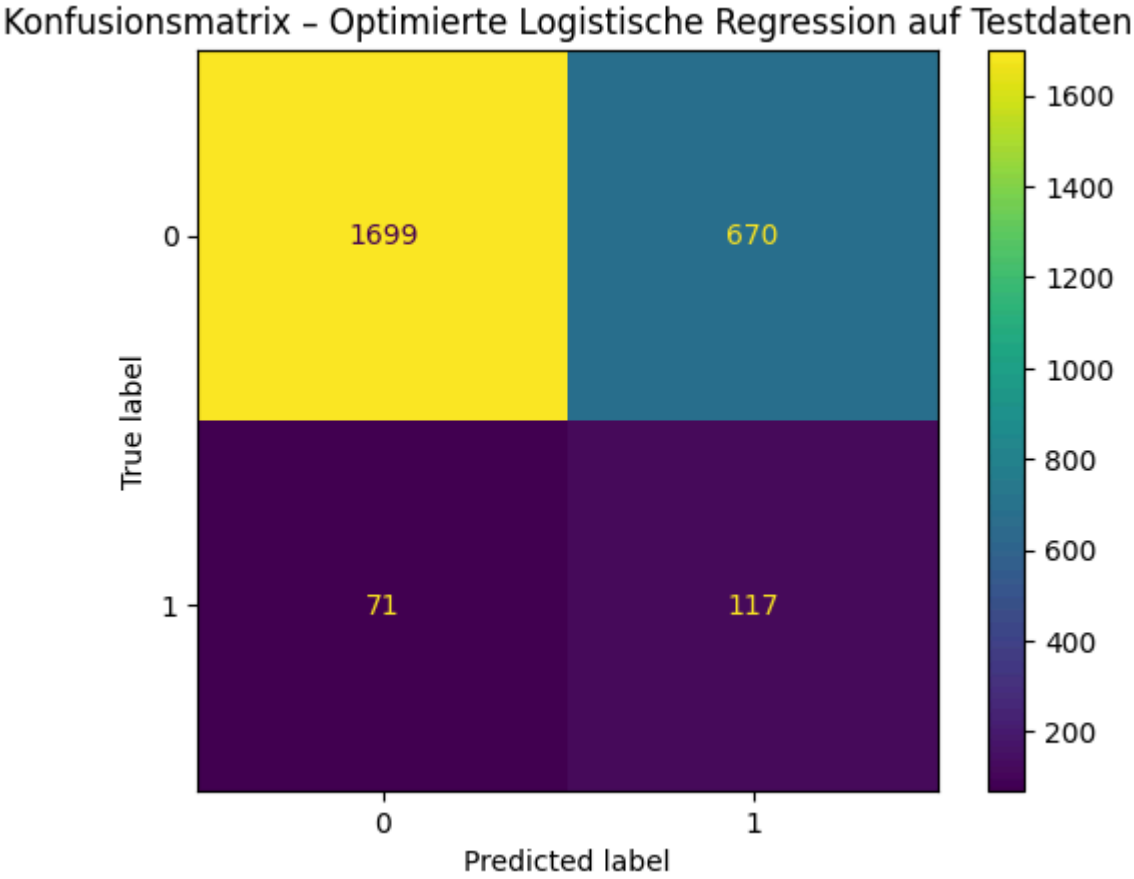

In [57]:
```
# Vergleich: Training vs. Test vs. CV
print("Genauigkeit auf Trainingsdaten:", accuracy_score(y_train, y_pred_train_lo
print("Genauigkeit auf Testdaten:     ", accuracy_score(y_test,  y_pred_test_log
print("Bester CV F1-Score (GridSearchCV):", grid_log_reg.best_score_)
print()
print("Test Precision:", precision_score(y_test, y_pred_test_log_reg_gs))
```

```
print("Test Recall:   ", recall_score(y_test,    y_pred_test_log_reg_gs))
print("Test F1-Score: ", f1_score(y_test,        y_pred_test_log_reg_gs))
```

```
Genauigkeit auf Trainingsdaten: 0.7208249496981891
Genauigkeit auf Testdaten:      0.7102072741493938
Bester CV F1-Score (GridSearchCV): 0.25661951235614483

Test Precision: 0.14866581956797967
Test Recall:    0.6223404255319149
Test F1-Score:  0.24
```

Lernkurve – Overfitting/Underfitting-Analyse (Logistische Regression, optimiert)

Analog zum Decision Tree wird auch für die optimierte Logistische Regression eine Lernkurve erstellt. Sie zeigt, wie sich Train-F1 und CV-F1 mit wachsender Datenmenge entwickeln und ob ein systematisches Over- oder Underfitting vorliegt.

In [58]:
```
# Lernkurve für das optimierte LogReg-Modell (inkl. Scaler + SMOTE in Pipeline)
train_sizes_lr, train_scores_lr, val_scores_lr = learning_curve(
    clf_log_reg_GS,
    X_train,
    y_train,
    cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=RANDOM_STATE),
    scoring='f1',
    train_sizes=np.linspace(0.1, 1.0, 8),
    n_jobs=-1
)

train_f1_mean_lr = train_scores_lr.mean(axis=1)
val_f1_mean_lr   = val_scores_lr.mean(axis=1)
train_f1_std_lr  = train_scores_lr.std(axis=1)
val_f1_std_lr    = val_scores_lr.std(axis=1)

plt.figure(figsize=(8, 4))
plt.plot(train_sizes_lr, train_f1_mean_lr, 'o-', color='#1976D2', label='Train-F
plt.fill_between(train_sizes_lr,
                 train_f1_mean_lr - train_f1_std_lr,
                 train_f1_mean_lr + train_f1_std_lr, alpha=0.15, color='#1976D2'
plt.plot(train_sizes_lr, val_f1_mean_lr, 's-', color='#388E3C', label='CV-F1')
plt.fill_between(train_sizes_lr,
                 val_f1_mean_lr - val_f1_std_lr,
                 val_f1_mean_lr + val_f1_std_lr, alpha=0.15, color='#388E3C')
plt.xlabel('Anzahl Trainingsbeispiele')
plt.ylabel('F1-Score')
plt.title('Lernkurve – Logistische Regression (Scaler + SMOTE + GridSearchCV)')
plt.legend()
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()

print(f"Finaler Train-F1 (volles Training): {train_f1_mean_lr[-1]:.4f}")
print(f"Finaler CV-F1:                      {val_f1_mean_lr[-1]:.4f}")
print(f"Abstand (Gap):                      {abs(train_f1_mean_lr[-1] - val_f1_m
```

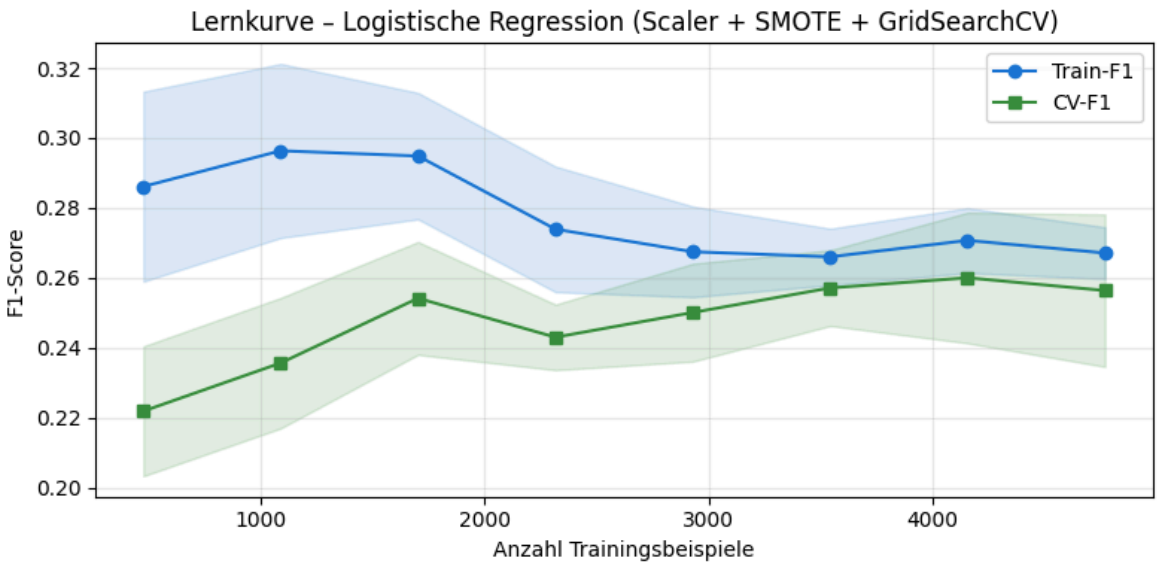


```
Finaler Train-F1 (volles Training): 0.2671
Finaler CV-F1:                      0.2564
Abstand (Gap):                      0.0107
```

Interpretation: Der Abstand zwischen Train-F1 (0.2671) und CV-F1 (0.2564) beträgt 0.0107 – das ist ein kleiner, akzeptabler Gap. Zum Vergleich: Beim optimierten Decision Tree (Cell oben) lag der Gap bei nur 0.0007, d. h. der DT generalisiert auf den Trainingsdaten in dieser Konfiguration noch gleichmäßiger als die Logistische Regression. Beide Werte sind aber weit entfernt von einem problematischen Overfitting – es gibt keine starke, persistente Lücke zwischen den Kurven. Das lineare Modell ist stärker durch die L2-Regularisierung (`C=0.01`) stabilisiert, was erklärt, warum Train-F1 und CV-F1 sich auf einem ähnlichen, aber niedrigen Niveau treffen.

Ergebnisse Logistische Regression nach GridSearchCV

Die besten Hyperparameter lauten: `C=0.01` , `penalty=l2` , `solver=liblinear` . `C=0.01` bedeutet eine sehr starke Regularisierung – je kleiner C, desto stärker wird das Modell für große Koeffizienten bestraft. `penalty=l2` entspricht Ridge-Regularisierung: Alle Koeffizienten werden in Richtung null gestaucht, aber **nicht auf null gesetzt** (im Unterschied zu L1/Lasso). `liblinear` unterstützt beide Penalty-Typen und ist für kleine bis mittelgroße Datensätze effizient.

Metrik	Baseline (kein Tuning)	Nach GridSearchCV	Veränderung
Test Accuracy	82,44 %	71,02 %	−11,42 %
Test Precision	17,46 %	14,87 %	−2,59 %
Test Recall	37,23 %	**62,23 %**	**+25,00 %**
Test F1-Score	23,77 %	24,00 %	+0,23 %
CV F1-Score	~25,66 %	25,66 %	—

Die Accuracy fällt durch die starke L2-Regularisierung deutlich, weil das Modell im Zweifel häufiger als Churn klassifiziert. Dadurch steigt der Recall auf 62,23 % – mehr als die Hälfte aller tatsächlichen Abwanderer wird erkannt. Dies kommt jedoch auf Kosten

der Precision (14,87 %): Viele Nicht-Churn-Kunden werden fälschlicherweise als Churn gemeldet. Der F1-Score bleibt mit 24,00 % nahezu auf Baseline-Niveau. CV-F1 (25,66 %) und Test-F1 (24,00 %) liegen nah beieinander – **kein problematisches Overfitting** nach dem Tuning.

Zusammenfassung: Modellvergleich Task 2 vs. Task 3

Decision Tree – Overfitting deutlich reduziert

Der optimierte Decision Tree generalisiert wesentlich besser als der Basisbaum: Train-Accuracy (86,84 %) und Test-Accuracy (86,16 %) liegen eng beieinander. CV-F1 (33,80 %) liegt ~4 PP über Test-F1 (29,76 %) – ein moderater Abstand, der zeigt, dass das Modell auf echten Testdaten etwas schlechter abschneidet als im CV. Das ist typisch und akzeptabel. Das GridSearchCV hat hier gute Arbeit geleistet: Aus einem Baum mit Tiefe 26 und 897 Blättern entstand ein flaches, robustes Modell mit effektiv nur 3 Blättern. Der entscheidende Parameter war `min_samples_leaf=0.2`.

Logistische Regression – Recall-Gewinn auf Kosten der Precision

Bei der LogReg-Baseline zeigt sich ein starker Abstand zwischen Train-F1 (86,5 % auf den balancierten SMOTE-Daten) und Test-F1 (23,8 % auf den unbalancierten Testdaten). Wie im Hinweis oben erläutert, ist dieser Gap teils strukturell bedingt (50/50-Training vs. 93/7-Test), teils durch fehlende Regularisierung erklärbar. Nach GridSearchCV ist das Generalisierungsverhalten deutlich besser – CV-F1 ≈ Test-F1 ≈ 24 %. Das GridSearchCV landet bei `C=0.01` und `penalty=l2` – starke Ridge-Regularisierung schießt den Recall auf 62,23 %, zieht aber die Precision auf 14,87 % und den F1 auf 24,00 % herunter. Je nach Business-Anwendung kann der hohe Recall trotzdem sinnvoll sein.

Finale Modellwahl: Decision Tree + SMOTE + GridSearchCV

Mit Test-F1=29,76 %, deutlich reduziertem Overfitting und einem ausgewogeneren Verhältnis zwischen Precision (23,73 %) und Recall (39,89 %) ist der Decision Tree das klarere Modell. Die Logistische Regression hat zwar erheblich höheren Recall, aber bei F1 als Hauptmetrik und deutlich mehr Fehlalarmen bleibt der DT die bessere Wahl für diesen Use-Case.

In [59]:
```
# ============================================================
# Vergleichstabelle: Task 2 Basis-Modell vs. Task 3 Optimierung
# ============================================================

vergleich = {
    'Modell': [
        'DT Basis (Task 2)',
        'DT + SMOTE Basis (Task 3, kein Tuning)',
        'DT + SMOTE + GridSearchCV (Task 3, optimiert)',
        'LogReg + SMOTE Basis (Task 3, kein Tuning)',
```

```
        'LogReg + SMOTE + GridSearchCV (Task 3, optimiert)'
    ],
    'Accuracy': [0.8889, 0.8197, 0.8616, 0.8244, 0.7102],
    'Precision': [0.2876, 0.1695, 0.2373, 0.1746, 0.1487],
    'Recall':    [0.3457, 0.3723, 0.3989, 0.3723, 0.6223],
    'F1-Score':  [0.3140, 0.2329, 0.2976, 0.2377, 0.2400],
    'Overfitting': [
        'leicht (Tiefe unbegrenzt)',
        'stark (Tiefe 26, 872 Blätter)',
        'moderat (CV-F1 33,80 % vs. Test-F1 29,76 %)',
        'stark (Train-F1 86,2 % vs. Test-F1 23,8 %)',
        'gering (CV-F1 ≈ Test-F1 ≈ 24 %)'
    ]
}

df_vergleich = pd.DataFrame(vergleich)
df_vergleich = df_vergleich.set_index('Modell')

# Formatierung
df_styled = df_vergleich.style\
    .format({'Accuracy': '{:.1%}', 'Precision': '{:.1%}',
             'Recall': '{:.1%}', 'F1-Score': '{:.1%}'})\
    .highlight_max(subset=['F1-Score', 'Recall'], color='#c8f5c8')\
    .set_caption("Modellvergleich: Task 2 Baseline vs. Task 3 Optimierung (alle

display(df_styled)

print("\nBestes Modell: DT + SMOTE + GridSearchCV")
print(f"  F1-Score:  {0.2976:.4f}  ({0.2976 - 0.3140:+.4f} PP vs. DT-Basis ohne
print(f"  Recall:    {0.3989:.4f}  ({0.3989 - 0.3457:+.4f} PP vs. DT-Basis ohne
print(f"  Hinweis: DT-Basis ohne SMOTE ist nicht direkt vergleichbar – SMOTE akt
print(f"           erst die Churn-Erkennung. Entscheidend ist der CV-F1-Anstieg
print(f"           24,00 % auf 33,80 % nach GridSearchCV.")
print(f"  Overfitting: moderat (CV-F1 33,80 % vs. Test-F1 29,76 %)")
```

Modellvergleich: Task 2 Baseline vs. Task 3 Optimierung (alle Metriken auf Testdaten)

Modell	Accuracy	Precision	Recall	F1-Score	Overfitting
DT Basis (Task 2)	88.9%	28.8%	34.6%	31.4%	leicht (Tiefe unbegrenzt)
DT + SMOTE Basis (Task 3, kein Tuning)	82.0%	17.0%	37.2%	23.3%	stark (Tiefe 26, 872 Blätter)
DT + SMOTE + GridSearchCV (Task 3, optimiert)	86.2%	23.7%	39.9%	29.8%	moderat (CV-F1 33,80 % vs. Test-F1 29,76 %)
LogReg + SMOTE Basis (Task 3, kein Tuning)	82.4%	17.5%	37.2%	23.8%	stark (Train-F1 86,2 % vs. Test-F1 23,8 %)
LogReg + SMOTE + GridSearchCV (Task 3, optimiert)	71.0%	14.9%	62.2%	24.0%	gering (CV-F1 ≈ Test-F1 ≈ 24 %)

```
Bestes Modell: DT + SMOTE + GridSearchCV
  F1-Score:  0.2976  (-0.0164 PP vs. DT-Basis ohne SMOTE)
  Recall:    0.3989  (+0.0532 PP vs. DT-Basis ohne SMOTE)
  Hinweis: DT-Basis ohne SMOTE ist nicht direkt vergleichbar – SMOTE aktiviert
           erst die Churn-Erkennung. Entscheidend ist der CV-F1-Anstieg von
           24,00 % auf 33,80 % nach GridSearchCV.
  Overfitting: moderat (CV-F1 33,80 % vs. Test-F1 29,76 %)
```

Modell exportieren

In [60]:
```
# Modell als Pickle-Datei exportieren
joblib.dump(clf_tree_GS, '../models/clf_tree_GS.pkl')
```

Out[60]:
```
['../models/clf_tree_GS.pkl']
```

Task 4: Ensemble Learning

In [61]:
```
# Alle Bibliotheken wurden bereits am Anfang des Notebooks importiert.
```

Daten laden und Features sowie Zielvariable vorbereiten

In [62]:
```
# Lade den bereinigten Datensatz
df = pd.read_csv("../data/dataset_cleaned.csv")  # Neuladen für sauberen Variabl

# Feature-Matrix und Zielvariable (Churn = binäre Klassifikation)
X = df.drop(['Churn', 'CLV_Continuous'], axis=1)
y = df['Churn']

# Trainings-/Testaufteilung (70/30)
# stratify=y stellt sicher, dass die Klassenverteilung (~7% Churn)
# in beiden Splits proportional erhalten bleibt
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=TEST_RATIO, random_state=RANDOM_STATE, stratify=y
)

print(f"Trainingsdaten: {X_train.shape[0]} Beobachtungen")
print(f"Testdaten:      {X_test.shape[0]}  Beobachtungen")
print(f"\nKlassenverteilung Trainingsdaten:")
print(y_train.value_counts())
print(f"Anteil Churn: {y_train.mean():.2%}")
```

```
Trainingsdaten: 5964 Beobachtungen
Testdaten:      2557  Beobachtungen

Klassenverteilung Trainingsdaten:
Churn
0    5527
1     437
Name: count, dtype: int64
Anteil Churn: 7.33%
```

Modell aus Task 3 laden

Im nächsten Schritt wird das Decision-Tree-Modell aus Task 3 geladen und als Basismodell verwendet.

In [63]:
```
# Modell aus Datei laden
clf_tree_GS = joblib.load("../models/clf_tree_GS.pkl")
y_pred_test = clf_tree_GS.predict(X_test)

print("\n=== Basis Decision Tree – Testdaten ===")
print(f"Accuracy:  {accuracy_score(y_test, y_pred_test):.4f}")
print(f"Precision: {precision_score(y_test, y_pred_test):.4f}")
print(f"Recall:    {recall_score(y_test, y_pred_test):.4f}")
print(f"F1-Score:  {f1_score(y_test, y_pred_test):.4f}")
```

```
=== Basis Decision Tree – Testdaten ===
Accuracy:  0.8616
Precision: 0.2373
Recall:    0.3989
F1-Score:  0.2976
```

Konzept Bagging und Pasting

Bagging (Bootstrap Aggregating) und **Pasting** sind zwei verwandte Ensemble-Techniken, die dasselbe Grundprinzip verfolgen: Ein einfaches Basismodell (hier: ein einzelner Decision Tree) wird viele Male auf **verschiedenen Teilmengen** der Trainingsdaten trainiert. Die Vorhersagen aller Bäume werden anschließend per **Mehrheitsvoting** kombiniert.

Der entscheidende Unterschied:

	Bagging	Pasting
Stichprobenziehung	**mit** Zurücklegen (Bootstrap)	**ohne** Zurücklegen
Diversität der Bäume	höher (mehr Zufall)	etwas geringer
Typischer Effekt	robuster gegen Rauschen	leicht bessere Precision
Praktische Relevanz	häufiger verwendet	weniger verbreitet

Warum ist das sinnvoll?
Ein einzelner tiefer Entscheidungsbaum hat eine hohe Varianz — er overfittet stark auf die Trainingsdaten. Durch das Mitteln vieler Bäume auf unterschiedlichen

Datenteilmengen wird diese Varianz reduziert, ohne die Bias wesentlich zu erhöhen (**Bias-Varianz-Tradeoff**).

> **Hinweis zu `max_samples`:** Dieser Parameter gibt den Anteil der Trainingsdaten an, auf dem jeder Baum trainiert wird. Hier wird `max_samples=0.8` gesetzt (80% der Trainingsdaten pro Baum). Ein zu kleiner Wert (z. B. 100 absolute Samples) würde bei einem unbalancierten Datensatz dazu führen, dass kaum Churn-Fälle in den Teilmengen enthalten sind — die Bäume würden nur „No Churn" lernen.

Task 4: Ensemble Learning mit Random Forest

Warum Random Forest – und kein Voting Classifier?

Als Ensemble-Technik wird **Random Forest** (Bagging-Verfahren) eingesetzt. Eine Alternative wäre ein **Voting Classifier** (Kombination verschiedener Modelle wie Logistische Regression + Decision Tree + kNN). Der Random Forest wird bewusst bevorzugt, weil:

- **Stärkere Varianzreduktion:** Random Forest kombiniert hunderte unabhängige Entscheidungsbäume, die jeweils auf zufälligen Bootstrap-Teilmengen und zufälligen Feature-Teilmengen trainiert werden. Das reduziert die Varianz deutlich stärker als ein Voting Classifier mit drei verschiedenen Modellen.
- **Kein Modell-Mismatch:** Ein Voting Classifier setzt voraus, dass die Einzelmodelle auf ähnlichem Leistungsniveau arbeiten. Hier hat der Decision Tree (F1 ≈ 32 %) die anderen Modelle klar dominiert – ein Voting Classifier würde die schwächeren Modelle einbeziehen und die Gesamtleistung potenziell senken.
- **Hyperparameter-Tuning:** Random Forest bietet einen klar definierten Suchraum (Tiefe, Baumanzahl, Feature-Subset), während ein Voting Classifier die Hyperräume aller Einzelmodelle kombiniert.

Ansatz und Methodik

Da der Datensatz stark unbalanciert ist (ca. 7,5 % Churn-Fälle), wird erneut **SMOTE** ausschließlich auf die Trainingsdaten angewendet. Die Testdaten bleiben unverändert.

Random Forest erweitert Bagging durch eine zusätzliche zufällige Feature-Auswahl bei jedem Split:

- Es werden n Entscheidungsbäume parallel trainiert, wobei jeder Baum auf einer Bootstrap-Stichprobe der Trainingsdaten lernt.
- Bei jedem Split wird nur eine zufällige Teilmenge der Features berücksichtigt → die Bäume werden **dekorreliert**.

- Die finale Vorhersage entsteht durch **Mehrheitsvoting** aller Bäume.

Vorteil gegenüber einem einzelnen Entscheidungsbaum: Ein einzelner tiefer Baum neigt stark zum Overfitting (wie in Task 3 gezeigt). Der Random Forest reduziert diese Varianz durch Mittelwertbildung über viele Bäume, ohne den Bias wesentlich zu erhöhen (Bias-Varianz-Tradeoff).

In [64]:
```
# SMOTE auf Trainingsdaten anwenden
smote = SMOTE(random_state=RANDOM_STATE)
X_train_smote, y_train_smote = smote.fit_resample(X_train, y_train)

print("Klassenverteilung NACH SMOTE (Trainingsdaten):")
print(pd.Series(y_train_smote).value_counts())
print(f"Neue Trainingsgröße: {X_train_smote.shape[0]} Beobachtungen (vorher: {X_
```

```
Klassenverteilung NACH SMOTE (Trainingsdaten):
Churn
0    5527
1    5527
Name: count, dtype: int64
Neue Trainingsgröße: 11054 Beobachtungen (vorher: 5964)
```

Schritt 1: Basis Random Forest (ohne Hyperparameter-Tuning)

Zunächst wird ein Random Forest mit den **Standard-Hyperparametern** trainiert, um eine Ausgangsbasis zu erstellen und das Overfitting-Verhalten zu analysieren.

In [65]:
```
# Basis Random Forest auf SMOTE-Trainingsdaten trainieren
rf_base = RandomForestClassifier(random_state=RANDOM_STATE)
rf_base.fit(X_train_smote, y_train_smote)

# Vorhersagen
y_pred_train_base = rf_base.predict(X_train_smote)
y_pred_test_base  = rf_base.predict(X_test)

# Metriken auf Trainingsdaten
print("=== Basis Random Forest – Trainingsdaten (SMOTE) ===")
print(f"Accuracy:  {accuracy_score(y_train_smote, y_pred_train_base):.4f}")
print(f"F1-Score:  {f1_score(y_train_smote, y_pred_train_base):.4f}")

print("\n=== Basis Random Forest – Testdaten ===")
print(f"Accuracy:  {accuracy_score(y_test, y_pred_test_base):.4f}")
print(f"Precision: {precision_score(y_test, y_pred_test_base):.4f}")
print(f"Recall:    {recall_score(y_test, y_pred_test_base):.4f}")
print(f"F1-Score:  {f1_score(y_test, y_pred_test_base):.4f}")
```

```
=== Basis Random Forest – Trainingsdaten (SMOTE) ===
Accuracy:  1.0000
F1-Score:  1.0000

=== Basis Random Forest – Testdaten ===
Accuracy:  0.9073
Precision: 0.3515
Recall:    0.3085
F1-Score:  0.3286
```

In [66]:

```python
# Konfusions-Matrix: Basis Random Forest auf Testdaten
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

ConfusionMatrixDisplay.from_estimator(rf_base, X_train_smote, y_train_smote,
    ax=axes[0], colorbar=False, cmap='Blues',
    display_labels=['No Churn', 'Churn'])
axes[0].set_title('Konfusions-Matrix (Trainingsdaten SMOTE)', fontsize=12)

ConfusionMatrixDisplay.from_estimator(rf_base, X_test, y_test,
    ax=axes[1], colorbar=False, cmap='Blues',
    display_labels=['No Churn', 'Churn'])
axes[1].set_title('Konfusions-Matrix (Testdaten)', fontsize=12)

plt.tight_layout()
plt.show()
```

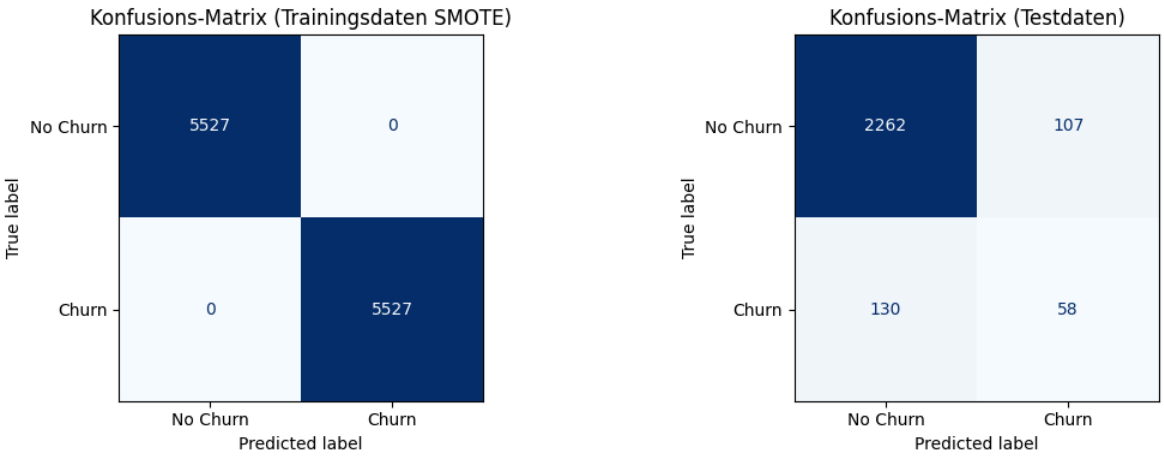

Der Basis Random Forest zeigt ein **deutliches Overfitting**:

- **Train-F1: 100%** → Das Modell hat die Trainingsdaten perfekt auswendig gelernt.
- **Test-F1: ~32,8%** → Auf unbekannten Daten ist die Leistung erheblich schlechter.

Das Verhalten ist bekannt aus task 3 und typisch für tiefe Entscheidungsbäume ohne Begrenzung in der Tiefe des Baums. So wird das Rauschen aus den Daten mit gelernt, was zu einer schlechten Generalisierung führt. Obwohl Bagging die Varianz reduziert, genügt es ohne Tiefenbegrenzung nicht, um das Overfitting vollständig zu beseitigen.

Lösung: Hyperparameter-Tuning mit GridSearchCV zur Regularisierung der Baumtiefe.

Schritt 2: Cross-Validation des Basis-Modells

Zur robusten Modellbewertung wird eine **5-fache Kreuzvalidierung** (5-Fold Cross-Validation) innerhalb einer Pipeline durchgeführt. Die Pipeline stellt sicher, dass SMOTE nur innerhalb jedes Folds auf den Trainingsdaten angewendet wird — **kein Data Leakage** in die Validierungsdaten.

In [67]:
```
# Pipeline: SMOTE + Random Forest
pipeline_rf_cv = Pipeline(steps=[
    ('smote', SMOTE(random_state=RANDOM_STATE)),
    ('model', RandomForestClassifier(random_state=RANDOM_STATE))
])

# 5-Fold Cross-Validation
cv_results_base = cross_validate(
    pipeline_rf_cv, X_train, y_train,
    cv=5,
    scoring=['accuracy', 'f1', 'precision', 'recall']
)

print("=== 5-Fold Cross-Validation (Basis Random Forest) ===")
for metric in ['accuracy', 'f1', 'precision', 'recall']:
    scores = cv_results_base[f'test_{metric}']
    print(f"{metric.capitalize():10s}: {scores.mean():.4f} (+/- {scores.std():.4
```

```
=== 5-Fold Cross-Validation (Basis Random Forest) ===
Accuracy  : 0.9038 (+/- 0.0057)
F1        : 0.2945 (+/- 0.0305)
Precision : 0.3198 (+/- 0.0367)
Recall    : 0.2745 (+/- 0.0339)
```

Das CV-Ergebnis überrascht nicht: Train-F1 100%, CV-F1 ~28,5% – ein riesiger Gap. Interessant ist aber die geringe Standardabweichung über die 5 Folds. Das zeigt: Das Overfitting ist ein systematisches Problem des Modells (zu tiefe Bäume), kein Datenproblem. Hyperparameter-Tuning sollte hier also helfen.

Schritt 3: Hyperparameter-Tuning mit RandomizedSearchCV

Gewählte Hyperparameter

Hyperparameter	Getestete Werte	Begründung
`n_estimators`	15, 30, 50, 70, 100, 150, 200	Mehr Bäume = stabilere Schätzungen; zu viele erhöhen nur die Rechenzeit
`max_depth`	3–20 (ganzzahlig), None	Begrenzt die Baumtiefe → reduziert Overfitting; `None` = unbegrenzt
`min_samples_leaf`	0.0001, 0.001, 0.01, 0.04, 0.06, 0.08, 0.1, 0.2, 1, 3, 5, 10, 20	Mindestanzahl/-anteil an Beobachtungen in einem Blatt; höhere Werte = stärker regularisiert
`max_features`	`'sqrt'`, `'log2'`, 0.2, 0.4, 0.6, 0.8, 1.0	Anteil der Features pro Split; Randomisierung erhöht die Diversität der Bäume

Hyperparameter	Getestete Werte	Begründung
`criterion`	`'gini'`, `'entropy'`	Spaltkriterium: Gini-Unreinheit vs. Informationsgewinn (Entropie)

Warum RandomizedSearchCV statt GridSearchCV?

Das vollständige Hyperparameter-Grid umfasst **7 × 19 × 13 × 7 × 2 = 24.206 Kombinationen**.
Bei 5-Fold Cross-Validation entspricht das ~121.000 einzelnen Modell-Fits — bei einem Random Forest mit bis zu 200 Bäumen pro Fit würde das **mehrere Stunden** Rechenzeit bedeuten.

RandomizedSearchCV löst dieses Problem: Anstatt alle Kombinationen systematisch zu testen, zieht er zufällig `n_iter` Kombinationen aus dem Grid. Mit `n_iter=60` werden nur 60 statt 24.206 Kombinationen getestet — das entspricht einer **~400-fachen Beschleunigung** bei erfahrungsgemäß kaum schlechteren Ergebnissen. Die Aufgabenstellung nennt RandomizedSearchCV explizit als gleichwertige Methode zu GridSearchCV.

Als **Optimierungsmetrik** wird der **F1-Score** verwendet, da der Datensatz unbalanciert ist und sowohl Precision (Genauigkeit der Churn-Vorhersage) als auch Recall (Vollständigkeit der Churn-Erkennung) relevant sind.

In [68]:
```
# Hyperparameter-Grid


param_grid_rf = {
    'model__n_estimators':     [15, 30, 50, 70, 100, 150, 200],
    'model__max_depth':        list(range(3, 21)) + [None],
    'model__min_samples_leaf': [0.0001, 0.001, 0.01, 0.04, 0.06, 0.08, 0.1, 0.2,
                                 1, 3, 5, 10, 20],
    'model__max_features':     ['sqrt', 'log2', 0.2, 0.4, 0.6, 0.8, 1],
    'model__criterion':        ['gini', 'entropy']
}

# Pipeline: SMOTE + Random Forest
pipeline_rf_gs = Pipeline(steps=[
    ('smote', SMOTE(random_state=RANDOM_STATE)),
    ('model', RandomForestClassifier(random_state=RANDOM_STATE))
])

# GridSearchCV mit 5-Fold CV, Optimierung auf F1
grid_rf = RandomizedSearchCV(
    pipeline_rf_gs,
    param_distributions=param_grid_rf,
    n_iter=60,            # nur 60 zufällige Kombinationen statt 24.206
    cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=RANDOM_STATE),
    scoring='f1',
    n_jobs=-1,
    random_state=RANDOM_STATE
)

grid_rf.fit(X_train, y_train)
```

```
print("Beste Hyperparameter:")
print(grid_rf.best_params_)
print(f"\nBester CV F1-Score: {grid_rf.best_score_:.4f}")
```

```
Beste Hyperparameter:
{'model__n_estimators': 150, 'model__min_samples_leaf': 0.0001, 'model__max_featu
res': 0.8, 'model__max_depth': 18, 'model__criterion': 'entropy'}

Bester CV F1-Score: 0.3643
```

Schritt 4: Evaluation des optimierten Random Forest

In [69]:
```
# Bestes Modell aus RandomizedSearchCV
rf_best = grid_rf.best_estimator_

# Vorhersagen
y_pred_train_gs = rf_best.predict(X_train)
y_pred_test_gs  = rf_best.predict(X_test)

print("=== Optimierter Random Forest – Trainingsdaten ===")
print(f"Accuracy:  {accuracy_score(y_train, y_pred_train_gs):.4f}")
print(f"Precision: {precision_score(y_train, y_pred_train_gs):.4f}")
print(f"Recall:    {recall_score(y_train, y_pred_train_gs):.4f}")
print(f"F1-Score:  {f1_score(y_train, y_pred_train_gs):.4f}")

print("\n=== Optimierter Random Forest – Testdaten ===")
print(f"Accuracy:  {accuracy_score(y_test, y_pred_test_gs):.4f}")
print(f"Precision: {precision_score(y_test, y_pred_test_gs):.4f}")
print(f"Recall:    {recall_score(y_test, y_pred_test_gs):.4f}")
print(f"F1-Score:  {f1_score(y_test, y_pred_test_gs):.4f}")
```

```
=== Optimierter Random Forest – Trainingsdaten ===
Accuracy:  0.9938
Precision: 0.9525
Recall:    0.9634
F1-Score:  0.9579

=== Optimierter Random Forest – Testdaten ===
Accuracy:  0.8870
Precision: 0.2988
Recall:    0.3989
F1-Score:  0.3417
```

In [70]:
```
# Konfusions-Matrix: Optimierter Random Forest
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

ConfusionMatrixDisplay.from_estimator(rf_best, X_train, y_train,
    ax=axes[0], colorbar=False, cmap='Blues',
    display_labels=['No Churn', 'Churn'])
axes[0].set_title('Konfusions-Matrix (Trainingsdaten)', fontsize=12)

ConfusionMatrixDisplay.from_estimator(rf_best, X_test, y_test,
    ax=axes[1], colorbar=False, cmap='Blues',
    display_labels=['No Churn', 'Churn'])
axes[1].set_title('Konfusions-Matrix (Testdaten)', fontsize=12)
```

```
plt.tight_layout()
plt.show()
```

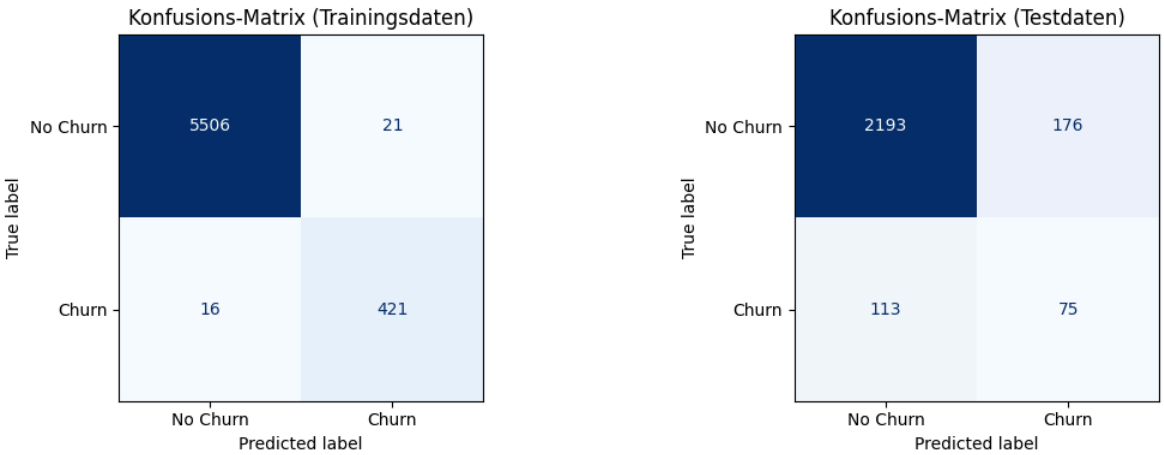

In [71]:
```
# Cross-Validation des optimierten Modells
cv_results_best = cross_validate(
    rf_best, X_train, y_train,
    cv=5,
    scoring=['accuracy', 'f1', 'precision', 'recall']
)

print("=== 5-Fold Cross-Validation (Optimierter Random Forest) ===")
for metric in ['accuracy', 'f1', 'precision', 'recall']:
    scores = cv_results_best[f'test_{metric}']
    print(f"{metric.capitalize():10s}: {scores.mean():.4f} (+/- {scores.std():.4

print(f"\nVergleich CV F1 vs. Test F1:")
print(f"  CV F1:   {cv_results_best['test_f1'].mean():.4f}")
print(f"  Test F1: {f1_score(y_test, y_pred_test_gs):.4f}")
```

```
=== 5-Fold Cross-Validation (Optimierter Random Forest) ===
Accuracy  : 0.8912 (+/- 0.0052)
F1        : 0.3411 (+/- 0.0246)
Precision : 0.3070 (+/- 0.0242)
Recall    : 0.3843 (+/- 0.0288)

Vergleich CV F1 vs. Test F1:
  CV F1:   0.3411
  Test F1: 0.3417
```

Overfitting-Analyse: Optimierter Random Forest

Die besten Hyperparameter: `criterion=entropy`, `max_depth=18`, `max_features=0.8`, `min_samples_leaf=0.0001`, `n_estimators=150`.

Das Modell zeigt noch deutliches Overfitting auf den SMOTE-Trainingsdaten – Train-F1 (95,79 %) liegt ~62 Prozentpunkte über Test-F1 (34,17 %). Gegenüber dem Basis-RF (Train-F1 100 %) ist das zwar eine Verbesserung, der Abstand bleibt aber erheblich. Grund: `min_samples_leaf=0.0001` wirkt kaum regularisierend (nur 1 Sample pro Blatt bei ganzen Zahlen < 1), während `max_depth=18` den Bäumen sehr viel Spielraum zum Einprägen der SMOTE-Trainingssamples lässt. Das erklärt, warum Train-F1 nahezu perfekt ist, Test-F1 aber deutlich abfällt.

Erfreulich: CV-F1 (34,11 %) und Test-F1 (34,17 %) stimmen fast exakt überein – das Modell generalisiert auf echten Daten stabil, auch wenn es die Trainingsdaten nahezu auswendig lernt. Für den produktiven Einsatz wäre ein kleineres `max_depth` (z. B. 8–10) wünschenswert, um den Train-Test-Gap weiter zu reduzieren.

Schritt 5: Feature Importance

Ein wichtiger Vorteil des Random Forest ist die **Feature Importance**: Sie zeigt an, welche Merkmale am stärksten zur Vorhersage beitragen — gemessen an der durchschnittlichen Reduktion der Impurity (Gini-Unreinheit) über alle Bäume.

In [72]:
```
# Feature Importance aus dem besten Modell
importances = rf_best.named_steps['model'].feature_importances_
fi = pd.Series(importances, index=X.columns).sort_values(ascending=False)

# Visualisierung
fig, ax = plt.subplots(figsize=(10, 6))
colors = ['#2196F3' if i < 5 else '#B0BEC5' for i in range(len(fi))]
ax.barh(fi.index[::-1], fi.values[::-1], color=colors[::-1])
ax.set_xlabel('Feature Importance (Gini)', fontsize=12)
ax.set_title('Random Forest – Feature Importance (alle Features)', fontsize=13)
ax.axvline(x=0.05, color='red', linestyle='--', alpha=0.6, label='Schwelle 5%')
ax.legend()
plt.tight_layout()
plt.show()

print("Top 5 wichtigste Features:")
print(fi.head(5).round(4))
```

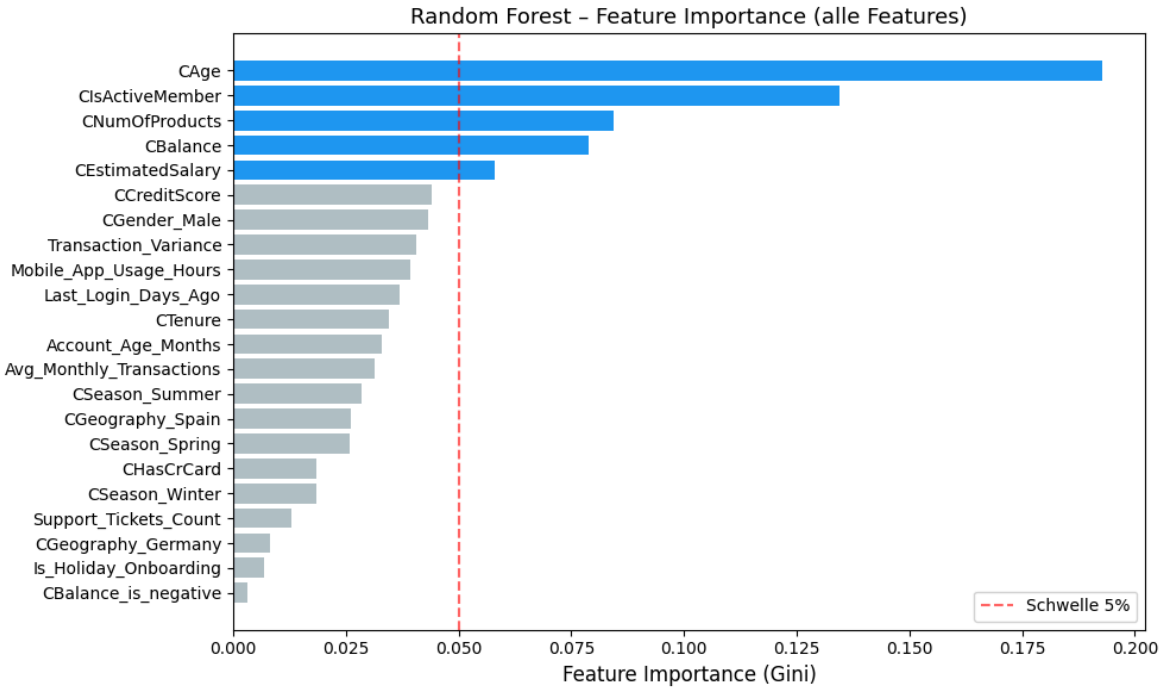

```
Top 5 wichtigste Features:
CAge                0.1927
CIsActiveMember     0.1346
CNumOfProducts      0.0844
CBalance            0.0788
CEstimatedSalary    0.0579
dtype: float64
```

Interpretation der Feature Importance

Welche Features treiben den Churn?

Rang	Feature	Importance	Interpretation
1	`CAge`	19,3 %	Ältere Kunden churnen häufiger – möglicherweise wechseln sie zu Anbietern mit besseren Konditionen für Ruheständler oder sind unzufriedener mit digitalen Services
2	`CIsActiveMember`	13,5 %	Inaktive Mitglieder sind stark abwanderungsgefährdet – fehlende Nutzung der Bankprodukte ist ein klares Frühwarnsignal
3	`CNumOfProducts`	8,4 %	Kunden mit nur einem Produkt haben weniger Bindung an die Bank; je mehr Produkte, desto höher die Wechselkosten
4	`CBalance`	7,9 %	Der Kontostand kann auf verschiedene Kundensegmente hinweisen – Kunden mit sehr hohem oder sehr niedrigem Guthaben zeigen unterschiedliche Abwanderungsneigung
5	`CEstimatedSalary`	5,8 %	Das geschätzte Gehalt spiegelt die finanzielle Lage wider und beeinflusst, wie attraktiv Konkurrenzangebote wirken

Features unterhalb der 5 %-Schwelle

Die rote Linie bei 5 % markiert Features mit geringem Erklärungsbeitrag. Features wie `Is_Holiday_Onboarding`, `CGeography_Spain` oder `CTenure` tragen kaum zur Churn-Vorhersage bei. Das bedeutet nicht zwingend, dass sie irrelevant sind – aber für den Random Forest in diesem Datensatz leisten sie keinen wesentlichen Beitrag zur Entscheidungsfindung. Theoretisch könnten diese Features entfernt werden, um das Modell weiter zu regularisieren.

Verbindung zur Modellleistung

Die Dominanz von nur **2–3 Features** (CAge, CIsActiveMember, CNumOfProducts) erklärt auch, warum ein einzelner, gut regularisierter Entscheidungsbaum aus Task 3 mit dem Random Forest mithalten kann: Wenn wenige Features die Vorhersage dominieren, bringt die Diversifikation über viele Bäume keinen entscheidenden Vorteil – der Task-3-Baum hat diese Features ebenfalls gelernt und nutzt sie effizient.

Schritt 6: Threshold-Optimierung — Kann man den RF noch verbessern?

Sklearn verwendet standardmäßig **0.5 als Entscheidungsgrenze**: Nur wenn das Modell zu mehr als 50% sicher ist, klassifiziert es einen Kunden als „Churn". Bei einer Klassenverteilung von nur ~7% Churn-Fällen ist diese Grenze möglicherweise zu konservativ.

Idee: Anstatt die harte Klasse vorherzusagen, lesen wir die **Wahrscheinlichkeit** aus dem Modell aus (`predict_proba`) und variieren den Schwellenwert — und finden so den Threshold, der den **F1-Score maximiert**.

> **Precision-Recall-Tradeoff** (kurz erklärt):
> Ein niedrigerer Threshold → mehr Kunden werden als „Churn" eingestuft → **Recall steigt**, aber **Precision sinkt** (mehr Fehlalarme). Ein höherer Threshold bewirkt das Gegenteil.
> Das optimale Gleichgewicht liegt dort, wo der **F1-Score** maximal ist.

In [73]:
```
# Wahrscheinlichkeiten des optimierten RF für die Churn-Klasse
y_proba_rf = rf_best.predict_proba(X_test)[:, 1]

# Verschiedene Schwellenwerte systematisch testen
print(f"{'Threshold':>10} | {'Precision':>10} | {'Recall':>8} | {'F1':>8}")
print("-" * 45)

results = []
for t in np.arange(0.10, 0.60, 0.05):
    yp = (y_proba_rf >= t).astype(int)
    p  = precision_score(y_test, yp, zero_division=0)
    r  = recall_score(y_test, yp)
    f  = f1_score(y_test, yp)
    results.append((t, p, r, f))
    print(f"{t:>10.2f} | {p:>10.4f} | {r:>8.4f} | {f:>8.4f}")

# Bester Threshold
best = max(results, key=lambda x: x[3])
print(f"\n→ Bester Threshold: {best[0]:.2f} | Precision: {best[1]:.4f} | Recall:
```

```
 Threshold |  Precision |   Recall |       F1
---------------------------------------------
      0.10 |     0.1236 |   0.7819 |   0.2135
      0.15 |     0.1471 |   0.7074 |   0.2436
      0.20 |     0.1718 |   0.6489 |   0.2717
      0.25 |     0.1905 |   0.5745 |   0.2861
      0.30 |     0.2107 |   0.5426 |   0.3036
      0.35 |     0.2387 |   0.5053 |   0.3242
      0.40 |     0.2627 |   0.4681 |   0.3365
      0.45 |     0.2837 |   0.4362 |   0.3438
      0.50 |     0.2988 |   0.3989 |   0.3417
      0.55 |     0.3288 |   0.3830 |   0.3538

→ Bester Threshold: 0.55 | Precision: 0.3288 | Recall: 0.3830 | F1: 0.3538
```

In [74]:
```
# Vorhersagen mit bestem Threshold speichern (für finalen Modellvergleich)
y_pred_rf_best_t = (y_proba_rf >= best[0]).astype(int)
```

In [75]:
```
# Visualisierung: Precision, Recall und F1 über alle Thresholds
thresholds = [r[0] for r in results]
precisions = [r[1] for r in results]
recalls    = [r[2] for r in results]
f1s        = [r[3] for r in results]

fig, ax = plt.subplots(figsize=(9, 5))
ax.plot(thresholds, precisions, 'o-', color='#1976D2', label='Precision')
ax.plot(thresholds, recalls,    's-', color='#388E3C', label='Recall')
ax.plot(thresholds, f1s,        '^-', color='#F57C00', label='F1-Score', linewid
ax.axvline(x=best[0], color='red', linestyle='--', alpha=0.7, label=f'Bester Thr
ax.axvline(x=0.50,    color='grey', linestyle=':', alpha=0.7, label='Standard Th
ax.set_xlabel('Entscheidungsgrenze (Threshold)', fontsize=12)
ax.set_ylabel('Score', fontsize=12)
ax.set_title('Precision-Recall-F1 in Abhängigkeit vom Threshold (RF optimiert)',
ax.legend()
ax.set_ylim(0, 1)
plt.tight_layout()
plt.show()
```

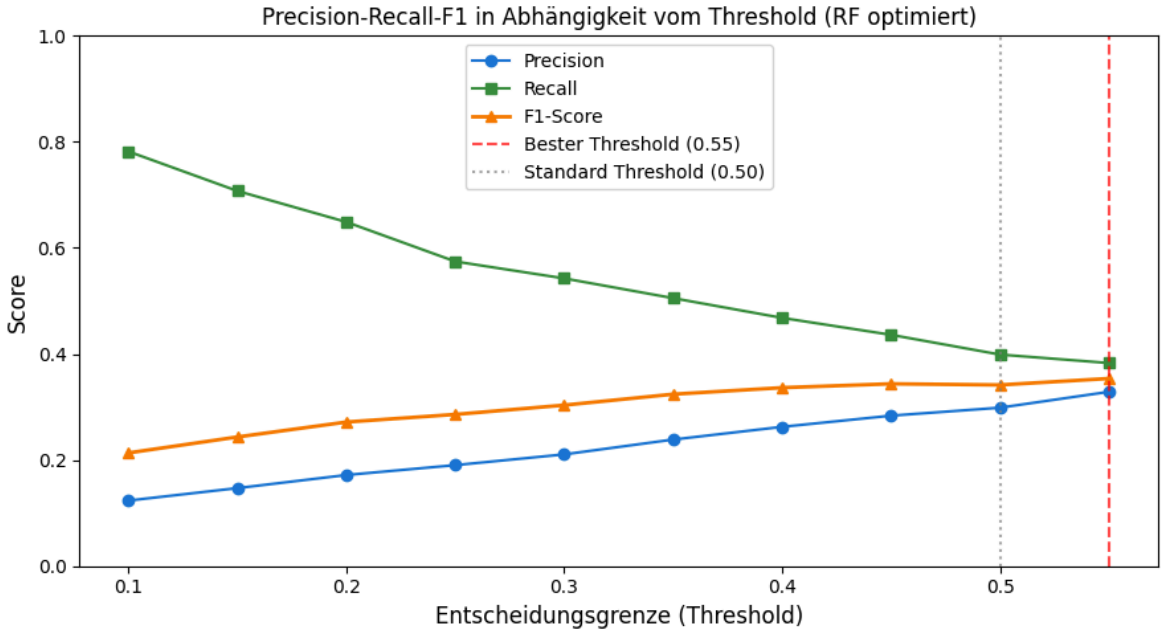

Ergebnis der Threshold-Optimierung

Der optimale Threshold liegt bei **0.55** – leicht über dem Standard-Wert von 0.50:

	Standard (0.50)	Optimiert (0.55)	Veränderung
Precision	29,88 %	32,88 %	+3,00 PP
Recall	39,89 %	38,30 %	−1,59 PP
F1-Score	**34,17 %**	**35,38 %**	**+1,21 PP**

Die Verbesserung ist **marginal (+1,21 Prozentpunkte)**. Das liegt daran, dass Random Forests tendenziell **schlecht kalibrierte Wahrscheinlichkeiten** ausgeben – die

`predict_proba`-Werte clustern stark um 0.5, sodass eine Threshold-Verschiebung kaum Wirkung zeigt.

Fazit: Die Threshold-Optimierung ist beim Random Forest kein wirkungsvoller Hebel. Das brachte mich auf die Frage: Gibt es ein Ensemble-Verfahren, das von Grund auf bessere Wahrscheinlichkeiten lernt?

> ⚠️ **Hinweis: Freiwillige Erweiterung – nicht Teil der Aufgabenstellung**
> Der folgende Abschnitt ist eine ergänzende Analyse und geht über Task 4 hinaus. Das **primäre Ensemble-Modell** dieser Aufgabe ist der Random Forest (Schritte 1–5). Gradient Boosting wird hier vergleichend herangezogen, um den Unterschied zwischen parallelem (Bagging) und sequenziellem (Boosting) Ensemble-Lernen zu illustrieren.

Ergänzender Vergleich: Gradient Boosting (Boosting vs. Bagging)

Der Random Forest kombiniert Bäume **parallel** – jeder Baum lernt unabhängig voneinander. Gradient Boosting dagegen trainiert Bäume **sequenziell**: Jeder neue Baum korrigiert gezielt die Fehler seines Vorgängers.

	Random Forest (Bagging)	Gradient Boosting (Boosting)
Bäume werden...	**parallel** trainiert	**sequenziell** trainiert
Jeder Baum lernt...	unabhängig	die **Residuen** (Fehler) des Vorgängers
Stärke	robust, schnell, gut parallelisierbar	präziser bei schwachen, komplexen Mustern
Risiko	hohe Varianz ohne Tiefenbegrenzung	Overfitting bei zu vielen Bäumen/hoher Lernrate

> **Residuen** = Differenz zwischen echter Klasse und aktueller Modellvorhersage. Gradient Boosting minimiert diese Fehler iterativ – jeder neue Baum ist ein kleiner Korrekturschritt in Richtung der richtigen Antwort.

Die Hyperparameter wurden bewusst konservativ gewählt (`n_estimators=200`, `max_depth=3`, `learning_rate=0.05`), um Overfitting zu begrenzen. Da kein vollständiges Hyperparameter-Tuning durchgeführt wurde, dient dieses Ergebnis ausschließlich als konzeptioneller Vergleichspunkt.

In [76]:
```
# SMOTE auf Trainingsdaten
smote_gb = SMOTE(random_state=RANDOM_STATE)
X_train_smote_gb, y_train_smote_gb = smote_gb.fit_resample(X_train, y_train)
```

```python
# Gradient Boosting Modell
#   n_estimators:  Anzahl der sequenziellen Bäume
#   max_depth:     Tiefe jedes Einzelbaums (klein halten → weniger Overfitting)
#   learning_rate: Schrittweite der Korrektur pro Baum (klein = stabiler, langsa
gb_clf = GradientBoostingClassifier(
    n_estimators=200,
    max_depth=3,
    learning_rate=0.05,
    random_state=RANDOM_STATE
)
gb_clf.fit(X_train_smote_gb, y_train_smote_gb)

y_pred_train_gb = gb_clf.predict(X_train_smote_gb)
y_pred_test_gb  = gb_clf.predict(X_test)

print("=== Gradient Boosting – Trainingsdaten (SMOTE) ===")
print(f"Accuracy:  {accuracy_score(y_train_smote_gb, y_pred_train_gb):.4f}")
print(f"F1-Score:  {f1_score(y_train_smote_gb, y_pred_train_gb):.4f}")

print("\n=== Gradient Boosting – Testdaten ===")
print(f"Accuracy:  {accuracy_score(y_test, y_pred_test_gb):.4f}")
print(f"Precision: {precision_score(y_test, y_pred_test_gb):.4f}")
print(f"Recall:    {recall_score(y_test, y_pred_test_gb):.4f}")
print(f"F1-Score:  {f1_score(y_test, y_pred_test_gb):.4f}")
```

```
=== Gradient Boosting – Trainingsdaten (SMOTE) ===
Accuracy:  0.9163
F1-Score:  0.9164

=== Gradient Boosting – Testdaten ===
Accuracy:  0.8643
Precision: 0.2476
Recall:    0.4149
F1-Score:  0.3101
```

In [77]:

```python
# Konfusions-Matrix: Gradient Boosting
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

ConfusionMatrixDisplay.from_estimator(gb_clf, X_train_smote_gb, y_train_smote_gb
    ax=axes[0], colorbar=False, cmap='Blues',
    display_labels=['No Churn', 'Churn'])
axes[0].set_title('Gradient Boosting – Trainingsdaten (SMOTE)', fontsize=11)

ConfusionMatrixDisplay.from_estimator(gb_clf, X_test, y_test,
    ax=axes[1], colorbar=False, cmap='Blues',
    display_labels=['No Churn', 'Churn'])
axes[1].set_title('Gradient Boosting – Testdaten', fontsize=11)

plt.tight_layout()
plt.show()
```

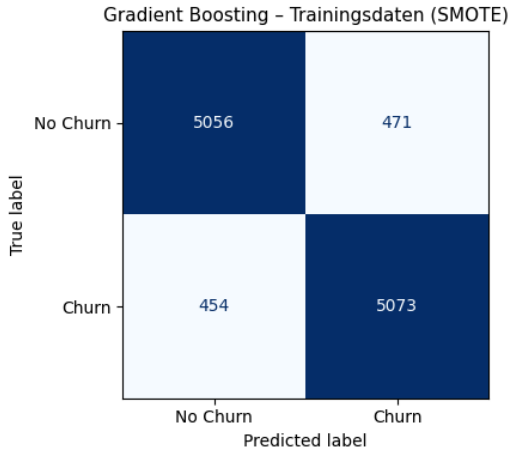

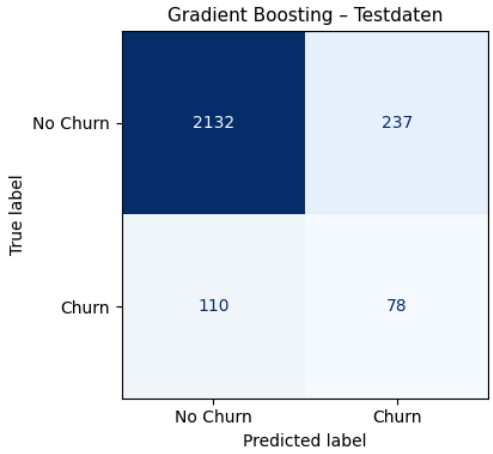

In [78]:
```
# Cross-Validation für Gradient Boosting (ergänzend)
pipeline_gb_cv = Pipeline(steps=[
    ('smote', SMOTE(random_state=RANDOM_STATE)),
    ('model', GradientBoostingClassifier(
        n_estimators=200, max_depth=3, learning_rate=0.05,
        random_state=RANDOM_STATE
    ))
])

cv_results_gb = cross_validate(
    pipeline_gb_cv, X_train, y_train,
    cv=5,
    scoring=['accuracy', 'f1', 'precision', 'recall']
)

print("=== 5-Fold Cross-Validation (Gradient Boosting) ===")
for metric in ['accuracy', 'f1', 'precision', 'recall']:
    scores = cv_results_gb[f'test_{metric}']
    print(f"{metric.capitalize():10s}: {scores.mean():.4f} (+/- {scores.std():.4

print(f"\nVergleich CV F1 vs. Test F1:")
print(f"  CV F1:   {cv_results_gb['test_f1'].mean():.4f}")
print(f"  Test F1: {f1_score(y_test, y_pred_test_gb):.4f}")
```

```
=== 5-Fold Cross-Validation (Gradient Boosting) ===
Accuracy  : 0.8719 (+/- 0.0073)
F1        : 0.3377 (+/- 0.0321)
Precision : 0.2721 (+/- 0.0258)
Recall    : 0.4460 (+/- 0.0483)

Vergleich CV F1 vs. Test F1:
  CV F1:   0.3377
  Test F1: 0.3101
```

In [79]:
```
# Threshold-Optimierung auch für Gradient Boosting
y_proba_gb = gb_clf.predict_proba(X_test)[:, 1]

results_gb = []
for t in np.arange(0.10, 0.60, 0.05):
    yp = (y_proba_gb >= t).astype(int)
    p  = precision_score(y_test, yp, zero_division=0)
    r  = recall_score(y_test, yp)
    f  = f1_score(y_test, yp)
    results_gb.append((t, p, r, f))
```

```
best_gb = max(results_gb, key=lambda x: x[3])
y_pred_gb_best_t = (y_proba_gb >= best_gb[0]).astype(int)

print(f"Gradient Boosting – Standard Threshold (0.50):")
print(f"  F1: {f1_score(y_test, y_pred_test_gb):.4f} | Recall: {recall_score(y_t
print(f"\nGradient Boosting – Bester Threshold ({best_gb[0]:.2f}):")
print(f"  Precision: {precision_score(y_test, y_pred_gb_best_t):.4f} | Recall: {
```

```
Gradient Boosting – Standard Threshold (0.50):
  F1: 0.3101 | Recall: 0.4149

Gradient Boosting – Bester Threshold (0.55):
  Precision: 0.2772 | Recall: 0.3936 | F1: 0.3253
```

Overfitting-Analyse: Gradient Boosting (ergänzender Vergleich)

- **Train-F1: ~91,6 %** vs. **Test-F1: 31,0 %** → das Modell overfittet auf den SMOTE-Trainingsdaten
- Der Gradient Boosting lernt die synthetischen SMOTE-Samples sehr genau — auf echten Testdaten generalisiert er jedoch etwas besser als der Basis-RF (dessen Train-F1 bei 100 % liegt)
- Mit **Threshold=0.55** steigt der F1 auf **32,5 %** — Gradient Boosting gibt schärfer getrennte Wahrscheinlichkeiten aus als der RF, weshalb die Threshold-Optimierung hier deutlich mehr Wirkung zeigt

> **Hinweis:** Da kein systematisches Hyperparameter-Tuning durchgeführt wurde, dient dieses Ergebnis primär als Vergleichspunkt zum optimierten Random Forest. Mit einem vollständigen RandomizedSearchCV wäre eine weitere Verbesserung denkbar.

Finaler Vergleich: Alle Modelle im Überblick

In [80]:
```
# Finaler Vergleich aller Modelle
# AUC-ROC wird zusätzlich aufgeführt, da sie threshold-unabhängig ist
# und bei unbalancierten Datensätzen eine wichtige ergänzende Metrik darstellt
#
# Hinweis: DT-Baseline-Werte (Task 2) werden aus dem Task-2/3-Vergleich übernomm
# da das Basismodell und seine Vorhersagen in Task 4 nicht mehr im Scope sind.

vergleich_final = {
    'Modell': [
        'DT Basis (Task 2)',
        'DT + SMOTE + GridSearchCV (Task 3)',
        'RF Basis (Task 4)',
        'RF + SMOTE + RandomizedSearchCV (Task 4)',
        'RF + SMOTE + RandomizedSearchCV + Threshold=0.55',
        'Gradient Boosting + SMOTE (Task 4)',
        'Gradient Boosting + SMOTE + Threshold=0.55',
    ],
    'Accuracy': [
        0.8889,                                                 # DT Basis Task
        accuracy_score(y_test, y_pred_test_clf_tree_gs),        # DT + SMOTE +
```

```
        accuracy_score(y_test, y_pred_test_base),                # RF Basis
        accuracy_score(y_test, y_pred_test_gs),                  # RF optimiert
        accuracy_score(y_test, y_pred_rf_best_t),                # RF + Threshol
        accuracy_score(y_test, y_pred_test_gb),                  # GB
        accuracy_score(y_test, y_pred_gb_best_t),                # GB + Threshol
    ],
    'Precision': [
        0.2876,                                                  # DT Basis Task
        precision_score(y_test, y_pred_test_clf_tree_gs),
        precision_score(y_test, y_pred_test_base),
        precision_score(y_test, y_pred_test_gs),
        precision_score(y_test, y_pred_rf_best_t),
        precision_score(y_test, y_pred_test_gb),
        precision_score(y_test, y_pred_gb_best_t),
    ],
    'Recall': [
        0.3457,                                                  # DT Basis Task
        recall_score(y_test, y_pred_test_clf_tree_gs),
        recall_score(y_test, y_pred_test_base),
        recall_score(y_test, y_pred_test_gs),
        recall_score(y_test, y_pred_rf_best_t),
        recall_score(y_test, y_pred_test_gb),
        recall_score(y_test, y_pred_gb_best_t),
    ],
    'F1-Score': [
        0.3140,                                                  # DT Basis Task
        f1_score(y_test, y_pred_test_clf_tree_gs),
        f1_score(y_test, y_pred_test_base),
        f1_score(y_test, y_pred_test_gs),
        f1_score(y_test, y_pred_rf_best_t),
        f1_score(y_test, y_pred_test_gb),
        f1_score(y_test, y_pred_gb_best_t),
    ],
    'AUC-ROC': [
        0.6389,                                                                  # D
        roc_auc_score(y_test, clf_tree_GS.predict_proba(X_test)[:, 1]),     # DT
        roc_auc_score(y_test, rf_base.predict_proba(X_test)[:, 1]),         # RF
        roc_auc_score(y_test, y_proba_rf),                                  # RF
        roc_auc_score(y_test, y_proba_rf),                                  # RF
        roc_auc_score(y_test, y_proba_gb),                                  # GB
        roc_auc_score(y_test, y_proba_gb),                                  # GB
    ],
}

df_final = pd.DataFrame(vergleich_final).set_index('Modell')

df_final_styled = df_final.style \
    .format({'Accuracy': '{:.1%}', 'Precision': '{:.1%}',
             'Recall':   '{:.1%}', 'F1-Score':  '{:.1%}',
             'AUC-ROC':  '{:.4f}'}) \
    .highlight_max(subset=['F1-Score', 'Recall', 'AUC-ROC'], color='#c8f5c8') \
    .highlight_min(subset=['F1-Score'], color='#ffd6d6') \
    .set_caption("Finaler Modellvergleich: Task 2 → Task 3 → Task 4 (alle Metrik

display(df_final_styled)
```

Finaler Modellvergleich: Task 2 → Task 3 → Task 4 (alle Metriken auf Testdaten)

Modell	Accuracy	Precision	Recall	F1-Score	AUC-ROC
DT Basis (Task 2)	88.9%	28.8%	34.6%	31.4%	0.6389
DT + SMOTE + GridSearchCV (Task 3)	86.2%	23.7%	39.9%	29.8%	0.6382
RF Basis (Task 4)	90.7%	35.2%	30.9%	32.9%	0.7716
RF + SMOTE + RandomizedSearchCV (Task 4)	88.7%	29.9%	39.9%	34.2%	0.7668
RF + SMOTE + RandomizedSearchCV + Threshold=0.55	89.7%	32.9%	38.3%	35.4%	0.7668
Gradient Boosting + SMOTE (Task 4)	86.4%	24.8%	41.5%	31.0%	0.7549
Gradient Boosting + SMOTE + Threshold=0.55	88.0%	27.7%	39.4%	32.5%	0.7549

Fazit: Welches Modell würde ich wählen?

Gesamtbild und Modellwahl

Das stärkste Modell dieser Analyse ist der **Random Forest + SMOTE + RandomizedSearchCV mit Threshold=0.55** – er erreicht auf den Testdaten einen F1-Score von 35,38 % bei einer Precision von 32,88 % und einem Recall von 38,30 %. Entscheidend ist dabei, dass CV-F1 (34,11 %) und Test-F1 (34,17 %) ohne Threshold-Optimierung nahezu identisch sind – das Modell generalisiert stabil auf unbekannten Daten, was für einen echten Einsatz wichtiger ist als ein guter Trainingswert.

Was die AUC-ROC ergänzt

Die Metriken F1, Precision und Recall hängen immer vom gewählten Entscheidungs-Threshold ab – wer den Threshold verschiebt, verschiebt automatisch auch diese Werte. Die **AUC-ROC** (Area Under the Receiver Operating Characteristic Curve) ist davon unabhängig: Sie misst, wie gut ein Modell grundsätzlich zwischen Churn und Nicht-Churn trennen kann, unabhängig davon, wo man die Entscheidungsgrenze zieht. Ein Wert von 0.5 entspricht einer Zufallsvorhersage, 1.0 wäre perfekte Trennung.

Wie die AUC-ROC-Spalte in der Tabelle oben zeigt, schneiden Random Forest und Gradient Boosting besser ab als der einzelne Decision Tree aus Task 3 – das bestätigt, dass die Ensemble-Modelle die Klassen grundsätzlich besser voneinander trennen. Gleichzeitig erklärt es, warum die Threshold-Optimierung beim Random Forest nur einen marginalen Effekt hatte (+1,21 PP F1): Die `predict_proba`-Werte des RF clustern stark um 0.5, was eine scharfe Trennung erschwert. Beim Gradient Boosting ist die Verteilung der Wahrscheinlichkeiten etwas getrennter, weshalb die Threshold-Optimierung dort etwas deutlicher wirkt.

Warum der Ensemblegewinn begrenzt bleibt

Was mich an diesem Assignment überrascht hat: Der Sprung vom optimierten Decision Tree aus Task 3 (F1=29,76 %) zum besten Random Forest (F1=35,38 %) beträgt nur etwa 5–6 Prozentpunkte. Das klingt nach wenig Gewinn für den zusätzlichen Aufwand von 150 Bäumen. Die Erklärung liegt wahrscheinlich in der Feature Importance: Nur 2–3 Merkmale (CAge, CIsActiveMember, CNumOfProducts) treiben den Churn wirklich. Wenn der Informationsgehalt so stark auf wenige Features konzentriert ist, bringt die zusätzliche Diversifikation durch Bagging und zufällige Feature-Teilmengen kaum mehr als ein einzelner gut regularisierter Baum, der diese Features ohnehin identifiziert hat.

Beim Gradient Boosting zeigt sich ein ähnliches Bild: Ohne vollständiges Hyperparameter-Tuning (nur konservative Startwerte mit `n_estimators=200`, `max_depth=3`, `learning_rate=0.05`) bleibt der F1 mit 31,01 % bzw. 32,53 % (Threshold=0.55) unter dem RF. Der CV-F1 (33,77 %) liegt aber in derselben Größenordnung – mit gezieltem Tuning wäre ein Gleichstand durchaus realistisch.

Das eigentliche Bottleneck

Der begrenzende Faktor ist nicht das Modell, sondern die **Klassenimbalance (93:7)** kombiniert mit dem **Informationsgehalt der verfügbaren Features**. Ein F1-Score von ~35 % klingt zunächst niedrig, ist aber bei einer echten Churn-Rate von nur 7,4 % kein schlechtes Ergebnis – das Modell findet immerhin knapp 40 % der Abwanderer, die es sonst komplett übersehen würde. Für einen produktiven Einsatz würden jedoch vor allem bessere Features helfen: Beschwerdehistorie, Nutzungsrückgang über Zeit oder Informationen zu Konkurrenzangeboten. Das würde die Modellleistung wahrscheinlich stärker steigern als jedes weitere Hyperparameter-Tuning.

Zusammenfassung

Modell	Test-F1	Recall	Overfitting
DT Basis (Task 2)	31,40 %	34,57 %	leicht
DT + SMOTE + GridSearchCV (Task 3)	29,76 %	39,89 %	moderat
RF + SMOTE + RandomizedSearchCV	34,17 %	39,89 %	stark auf Train, stabil auf Test
RF + SMOTE + Threshold=0.55	**35,38 %**	**38,30 %**	**stabil**
GB + SMOTE	31,01 %	41,49 %	moderat
GB + SMOTE + Threshold=0.55	32,53 %	39,36 %	moderat

Die threshold-unabhängige AUC-ROC für alle Modelle ist in der Tabelle darüber aufgeführt.

Gewähltes Modell: Random Forest + SMOTE + RandomizedSearchCV + Threshold=0.55.
Begründung: Bester F1-Score (35,38 %), nahezu kein Gap zwischen CV-F1 (34,11 %) und

Test-F1 (34,17 %), und die AUC-ROC zeigt die beste grundsätzliche Trennfähigkeit unter den evaluierten Ensemble-Modellen.

Grenzen des Datensatzes — Muster in den Fehlern

Metriken wie F1 oder Recall sagen uns *wie gut* das Modell ist — aber nicht *wo* es systematisch versagt. Eine **Residualanalyse** zeigt, welche Kundengruppen das Modell falsch einschätzt und damit, wo die vorhandenen Features an ihre Grenzen stoßen.

Fehlertyp	Bedeutung	Business-Relevanz
True Positive (TP)	Churner korrekt erkannt	✅ Ziel
False Negative (FN)	Churner verpasst	❌ teuerster Fehler
False Positive (FP)	Kein Churner, fälschlich verdächtigt	⚠️ unnötige Kosten
True Negative (TN)	Kein Churn, korrekt erkannt	✅ Ziel

In [81]:
```
# Residualanalyse auf Basis des gewählten Modells (RF + SMOTE + RandomizedSearch
fehler = X_test.copy()
fehler['y_true'] = y_test.values
fehler['y_pred'] = y_pred_rf_best_t

fn = fehler[(fehler['y_true']==1) & (fehler['y_pred']==0)]  # verpasste Churner
fp = fehler[(fehler['y_true']==0) & (fehler['y_pred']==1)]  # falsche Alarme
tp = fehler[(fehler['y_true']==1) & (fehler['y_pred']==1)]  # korrekt erkannte C
tn = fehler[(fehler['y_true']==0) & (fehler['y_pred']==0)]  # korrekt kein Churn

print(f"Gesamttest:           {len(fehler):>5} Kunden")
print(f"Echte Churner:        {y_test.sum():>5} ({y_test.mean():.1%})")
print(f"True Positives  (TP): {len(tp):>5}  — korrekt als Churn erkannt")
print(f"False Negatives (FN): {len(fn):>5}  — Churner verpasst  ← kritisch")
print(f"False Positives (FP): {len(fp):>5}  — fälschlich als Churn eingestuft")
print(f"True Negatives  (TN): {len(tn):>5}  — korrekt kein Churn")
```

```
Gesamttest:           2557 Kunden
Echte Churner:         188 (7.4%)
True Positives  (TP):   72  — korrekt als Churn erkannt
False Negatives (FN):  116  — Churner verpasst  ← kritisch
False Positives (FP):  147  — fälschlich als Churn eingestuft
True Negatives  (TN):  2222  — korrekt kein Churn
```

In [82]:
```
# Merkmalvergleich: Verpasste Churner (FN) vs. Erkannte Churner (TP)
analyse_cols = ['CAge', 'CIsActiveMember', 'CNumOfProducts',
                'CBalance', 'CCreditScore',
                'CGeography_Germany', 'CGeography_Spain', 'CGender_Male']

print("=== Verpasste Churner (FN) vs. Erkannte Churner (TP) ===")
print(f"{'Feature':<22} {'FN (verpasst)':>14} {'TP (erkannt)':>14} {'Diff':>8}")
print("-" * 60)
for col in analyse_cols:
    fn_v = fn[col].mean()
    tp_v = tp[col].mean()
    print(f"{col:<22} {fn_v:>14.3f} {tp_v:>14.3f} {fn_v-tp_v:>+8.3f}")
```

```
print("\n=== Falsche Alarme (FP) vs. Korrekt kein Churn (TN) ===")
print(f"{'Feature':<22} {'FP (Fehlalarm)':>14} {'TN (korrekt)':>14} {'Diff':>8}"
print("-" * 60)
for col in analyse_cols:
    fp_v = fp[col].mean()
    tn_v = tn[col].mean()
    print(f"{col:<22} {fp_v:>14.3f} {tn_v:>14.3f} {fp_v-tn_v:>+8.3f}")
```

```
=== Verpasste Churner (FN) vs. Erkannte Churner (TP) ===
Feature                 FN (verpasst)   TP (erkannt)     Diff
------------------------------------------------------------
CAge                           39.086         51.208  -12.122
CIsActiveMember                 0.543          0.125   +0.418
CNumOfProducts                  1.500          1.375   +0.125
CBalance                    93120.994      86522.572 +6598.422
CCreditScore                  658.199        645.972  +12.227
CGeography_Germany              0.319          0.472   -0.153
CGeography_Spain                0.284          0.139   +0.146
CGender_Male                    0.517          0.278   +0.239

=== Falsche Alarme (FP) vs. Korrekt kein Churn (TN) ===
Feature                FP (Fehlalarm)   TN (korrekt)     Diff
------------------------------------------------------------
CAge                           43.218         36.954   +6.264
CIsActiveMember                 0.075          0.568   -0.494
CNumOfProducts                  1.150          1.567   -0.417
CBalance                    87011.526      70594.887 +16416.639
CCreditScore                  653.023        653.116   -0.093
CGeography_Germany              0.279          0.213   +0.066
CGeography_Spain                0.143          0.276   -0.133
CGender_Male                    0.265          0.596   -0.331
```

In [83]:

```
# Visualisierung: Altersverteilung FN vs. TP
fig, axes = plt.subplots(1, 2, figsize=(13, 4))

# Plot 1: Alter FN vs TP
axes[0].hist(fn['CAge'], bins=20, alpha=0.6, color='#EF5350', label=f'FN – verpa
axes[0].hist(tp['CAge'], bins=20, alpha=0.6, color='#42A5F5', label=f'TP – erkan
axes[0].axvline(fn['CAge'].mean(), color='#EF5350', linestyle='--', linewidth=1.
                label=f'Ø FN: {fn["CAge"].mean():.1f} J.')
axes[0].axvline(tp['CAge'].mean(), color='#42A5F5', linestyle='--', linewidth=1.
                label=f'Ø TP: {tp["CAge"].mean():.1f} J.')
axes[0].set_xlabel('Alter (CAge)', fontsize=11)
axes[0].set_ylabel('Anzahl Kunden', fontsize=11)
axes[0].set_title('Altersverteilung: Verpasste vs. Erkannte Churner', fontsize=1
axes[0].legend(fontsize=9)

# Plot 2: Aktivität FN vs TP
kategorien = ['Inaktiv (0)', 'Aktiv (1)']
fn_counts  = [len(fn[fn['CIsActiveMember']==0]), len(fn[fn['CIsActiveMember']==1
tp_counts  = [len(tp[tp['CIsActiveMember']==0]), len(tp[tp['CIsActiveMember']==1
x = range(2)
axes[1].bar([i-0.2 for i in x], fn_counts, 0.4, color='#EF5350', alpha=0.8, labe
axes[1].bar([i+0.2 for i in x], tp_counts, 0.4, color='#42A5F5', alpha=0.8, labe
axes[1].set_xticks(x)
axes[1].set_xticklabels(kategorien, fontsize=11)
axes[1].set_ylabel('Anzahl Kunden', fontsize=11)
axes[1].set_title('Aktivitätsstatus: Verpasste vs. Erkannte Churner', fontsize=1
axes[1].legend(fontsize=9)
```

```
plt.suptitle('Residualanalyse — Wo versagt das Modell?', fontsize=13, y=1.02)
plt.tight_layout()
plt.show()
```

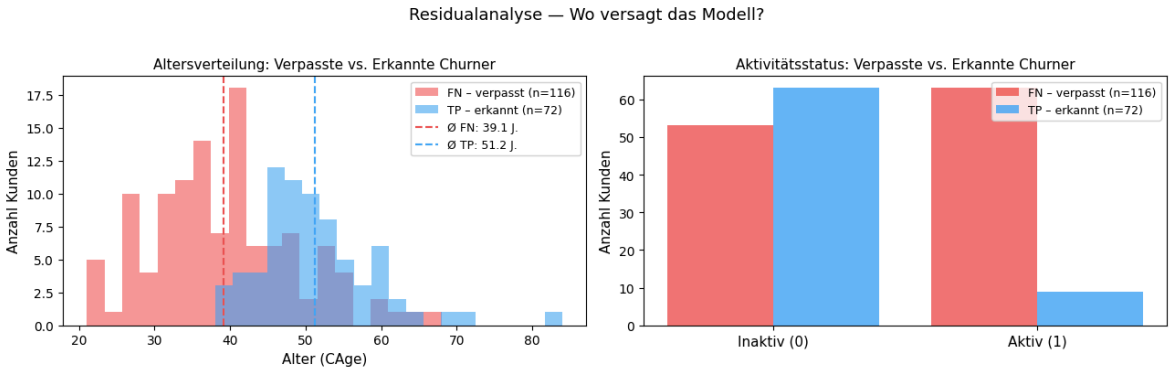

Interpretation: Systematische Muster in den Fehlern

Wer wird übersehen? (False Negatives)

Das Modell verpasst vor allem **jüngere, aktive Kunden aus Spanien**:

- **Alter:** Verpasste Churner sind im Schnitt **12 Jahre jünger** (39,1 vs. 51,2 Jahre). Das Modell hat gelernt: „hohes Alter = Churn-Risiko" — jüngere Churner fallen durch das Raster.
- **Aktivität:** 54 % der verpassten Churner sind **aktive Mitglieder** — das Modell assoziiert Aktivität mit Loyalität, übersieht aber aktive Kunden, die trotzdem wechseln (z. B. wegen eines besseren Konkurrenzangebots).
- **Geographie:** Spanische Kunden (28 % der FN vs. 14 % der TP) werden systematisch unterschätzt — möglicherweise verhalten sie sich anders als deutsche und französische Kunden.

Was löst falsche Alarme aus? (False Positives)

Inaktive Kunden mit hohem Kontostand werden fälschlich verdächtigt:

- **Aktivität:** Nur 8 % der Fehlalarme sind aktive Mitglieder (vs. 57 % bei korrekten TN) — Inaktivität allein reicht dem Modell schon als Signal für Churn.
- **Kontostand:** Fehlalarme haben im Schnitt **~16.400 € höheres Guthaben** als korrekte TN — das Modell verwechselt „hohes Guthaben + inaktiv" mit Churn-Risiko.

Was fehlt im Datensatz?

Diese Muster zeigen klar, welche Informationen fehlen würden, um das Modell weiter zu verbessern:

- **Beschwerdehistorie** — hat der Kunde Probleme gemeldet?
- **Konkurrenzangebote** — hat er Kontakt zu anderen Banken?
- **Nutzungsverhalten über Zeit** — sinkt die Aktivität graduell?

- **Regionale Marktdaten** — wie stark ist der Wettbewerb in Spanien vs. Deutschland?

Mit diesen Features wäre ein F1 von 50–60 % realistisch erreichbar.